Zdania PK sterują odczytaniem modeli, które przeszły kontrolę: trafność od 70 % do 99 %; zdanie zwykłe dzieli te modele w 73 % pozycji

Każdy wiersz to 1 pozycja; pozycje uporządkowane według odpowiedzi modelu na zdanie zwykłe

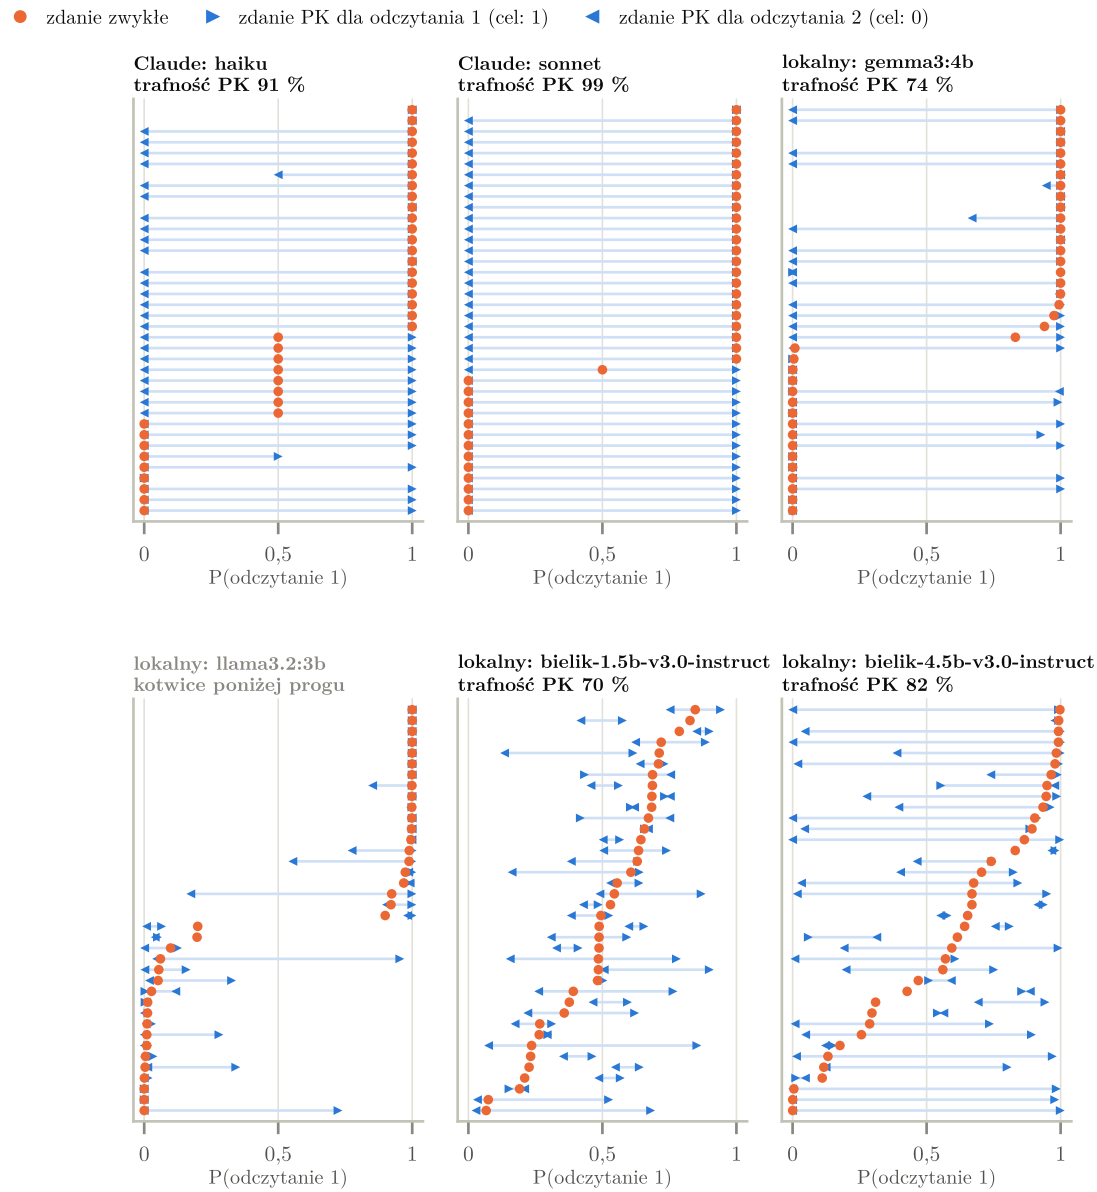

Źródło: results/p4_summary.json; n = 38 pozycji przeredagowanych na model, 6 modeli. Modele Claude: udział odpowiedzi „Tak” w 2 próbach.