Sprawozdanie z pomiarów

do pracy „Polszczyzna kontrolowana jako metoda redukcji złożoności obliczeniowej w AI”

Maciej Szulia
maciej.szulia@gmail.com

2026-11-12

1 Zakres

Sprawozdanie opisuje 5 pomiarów pracy: warunki, wyniki, odstępstwa od planu i sposób odtworzenia. Autor napisał sprawozdanie w PK. Legenda: „lub” znaczy co najmniej 1 z członów; „albo” znaczy dokładnie 1 z członów. Znacznik w nawiasie kwadratowym podaje źródło faktu. Każda liczba w tabelach pochodzi z plików katalogu `results` „[obliczenie: scripts/measure.py]”.

2 Środowisko

Element	Wartość
Data pomiarów	2026-11-12
Komputer	procesor Intel Core i7-7700HQ, 8 wątków, 31 GB pamięci
System	Linux 7.2.9, dystrybucja Artix
Python	3.13.14
Program `ollama`	0.34.1, obliczenia na procesorze
Polecenie `claude`	2.1.322
Przedmiot badania	standard PK 0.1, wersja `15503a4`

Źródło danych tabeli: „[obserwacja: 2026-11-12, 18:31]”.

3 Wyniki zbiorcze

Pomiar	Wielkość	Wynik	Plik wyników
P1	liczba odczytań zdania z 8 frazami przyimkowymi	4862 odczytania; zdanie PK: 1	`p1_counts.json`
P2	wykładnik wzrostu liczby operacji parsera	2,53 bez reguł PK; 1,77 z regułą B6	`p2_parser.json`
P3	narzut długości PK w tokenach o200k	mediana 37 %; kwartyle 13 % i 63 %	`p3_tokens.json`
P4	trafność odczytania zdań PK przez model	od 70 % do 99 % włącznie (modele po kontroli kotwic)	`p4_summary.json`
P4	rozbieżność modeli na zdaniu zwykłym	32 z 44 pozycji	`p4_summary.json`
P5	trafienia sprawdzarki na 1000 słów	akty prawne: od 43 do 71 włącznie; teksty PK: od 0,0 do 3,5 włącznie	`p5_corpus.json`
P5	precyzja sprawdzarki	57 z 60 trafień, czyli 95 %	`summary.json`

Kontrole poprawności: test redukcji z problemu 3-SAT przeszedł 400 z 400 formuł. Sprawdzarka wykrywa 26 z 44 zdań zwykłych zbioru testowego i nie zgłasza żadnego z 88 zdań PK.

4 Pomiar P4: biegi i wyniki

Zbiór ma 44 pozycji: 38 przeredagowań, 4 konwencje i 2 luki. Pełna sonda ma 408 różnych zapytań na model. Tor Claude obejmuje 136 zapytań strefy szarej, każde w 2 próbach.

Tabela 1: Biegi sondy. Czas obejmuje nowe wywołania 1 biegu; bieg wznowiony ma osobny wiersz.

Tor	Model	nowe zapytania	czas (min)
Claude	`haiku`	102	15,6
Claude	`sonnet`	136	21,8
Claude	`haiku`	1	0,2
Claude	`sonnet`	3	0,7
lokalny	`llama3.2:3b`	402	26,3
lokalny	`SpeakLeash/bielik-1.5b-v3.0-instruct:Q8_0`	408	14,9
lokalny	`gemma3:4b`	408	42,5
lokalny	`SpeakLeash/bielik-4.5b-v3.0-instruct:Q8_0`	408	28,7

Tabela 2: Wynik sondy. L: tor lokalny, C: tor Claude. n: liczba pozycji typu przeredagowanie. H: mediana niepewności w bitach. Znaki: liczba pozycji z niepewnością wyższą dla zdania zwykłego i liczba pozycji z niepewnością wyższą dla zdań PK; p: test znaków. Kotwice: trafność w procentach; próg kwalifikacji modelu wynosi 80 %.

		H (bity)		test znaków			trafność	kotwice (%)	
Model	n	zwykłe	PK	znaki	p	sterow.	PK (%)	zwykłe	PK
C: haiku	38	–	–	–	–	0,84	91	–	–
C: sonnet	38	–	–	–	–	0,97	99	–	–
L: gemma3:4b	38	0,00	0,00	17:21	0,627	0,48	74	89	86
L: llama3.2:3b	38	0,06	0,06	20:18	0,871	0,12	54	67	65
L: bielik-1.5b-v3.0-instruct	38	0,91	0,89	24:14	0,143	0,19	70	90	86
L: bielik-4.5b-v3.0-instruct	38	0,61	0,44	23:15	0,256	0,50	82	92	88

Tabela 3: Pozycje typu konwencja (4 pozycje, reguły B2 i C1): trafność w procentach i sterowalność bez legendy oraz z legendą.

Model	trafność bez legendy	trafność z legendą	sterowalność bez legendy	sterowalność z legendą
C: haiku	75	100	0,50	1,00
C: sonnet	62	100	0,25	1,00
L: gemma3:4b	50	50	0,11	0,00
L: llama3.2:3b	62	62	0,11	0,17
L: bielik-1.5b-v3.0-instruct	62	50	0,10	0,03
L: bielik-4.5b-v3.0-instruct	50	75	0,20	0,35

Kontrolę kotwic przeszło 5 z 6 modeli; modele toru Claude nie mają kotwic i wchodzą do zestawienia na podstawie trafności PK. W 32 z 44 pozycji modele po kontroli wybierają różne odczytania zdania zwykłego. W 12 z 44 pozycji każdy model po kontroli odczytuje oba zdania PK zgodnie z kluczem.

5 Pomiary P3 i P5

Tabela 4: P3: narzut długości PK w procentach długości zdania zwykłego; 40 pozycji.

Miara	mediana	kwartyl 1	kwartyl 3	minimum	maksimum	dłuższe (%)
słowa	38	15	83	−33	290	78
znaki	39	13	73	−17	400	85
o200k	37	13	63	−4	286	90
cl100k	37	12	66	−12	292	85
Llama 3.2 3B	39	12	70	−7	292	85
Gemma 3 4B	36	19	64	4	285	94

Tabela 5: P5: wynik sprawdzarki na korpusie. Mediana: mediana długości zdania w słowach. Kolumna 4: udział zdań dłuższych niż 25 słów. Trafienia: liczba na 1000 słów. Kolumna końcowa: wystąpienia słowa „się” na 1000 słów, kandydat do oceny.

Tekst	słowa	mediana	ponad 25 (%)	trafienia	„się”
Konstytucja Rzeczypospolitej Polskiej	13 057	13	12	48,2	9,2
Kodeks cywilny	60 216	17	28	71,2	15,6
Kodeks pracy	49 374	18	35	48,5	8,7
Prawo o ruchu drogowym	83 125	23	45	43,3	8,7
Zasady techniki prawodawczej	14 029	16	29	50,3	36,3
Standard PK 0.1	1875	4	0	2,7	1,1
Praca „Rachunek generatorów”	3687	8	0	3,5	1,4
Niniejsza praca	7513	9	0	0,0	2,7

Tokenizery modeli Bielik wymagają zgody licencyjnej w serwisie Hugging Face; żądanie pliku zwróciło błąd 401 „[obserwacja: 2026-11-12, 17:52]”. Pomiar P3 obejmuje więc 4 tokenizery.

6 Odstępstwa od planu i problemy

1. **Tor OpenRouter nie powstał.** Plan przewidywał 3 tory pomiaru P4. Zabezpieczenie komputera autora zablokowało odczyt klucza dostępu „[obserwacja: 2026-11-12, 15:15]”. Pomiar ma 2 tory: lokalny i Claude.
2. **Zbiór ma 44 pozycji.** Plan przewidywał 40 pozycji. Dodatkowe pozycje to 2 luki standardu (G1, G2) i 2 pozycje o słowach kluczowych (K1, K2).
3. **Kontrola kotwic.** Kontroli kotwic nie przeszło 1 z 4 modeli lokalnych. Wynik takiego modelu stoi w tabeli 2 i nie wchodzi do miar zgodności.
4. **Tor Claude nie ma kotwic.** Budżet toru wynosił co najwyżej 600 wywołań, więc tor obejmuje tylko sondy strefy szarej w 2 próbach.
5. **Przerwa toru Claude.** O godz. 18:06 polecenie `claude` zniknęło na czas aktualizacji pakietu i bieg zakończył się błędem. Autor dodał do skryptu ponawianie i wznowił bieg; skrypt zachował odpowiedzi sprzed przerwy „[obserwacja: 2026-11-12, 18:07]”. Bieg przerwany wykonał 34 zapytania i nie ma wiersza w tabeli 1.
6. **Odczyt werdyktu w torze Claude.** W 4 sondach model napisał rachunek przed werdyktem, a skrypt odczytywał werdykt z początku odpowiedzi. Autor zmienił regułę: werdyktem jest końcowe słowo odpowiedzi. Autor powtórzył te 4 sondy (8 wywołań) i przeliczył 1 wynik z zapisanej odpowiedzi. Tor Claude zużył razem 552 wywołania.

7. **Tokenizery modeli Bielik.** Serwis Hugging Face zwrócił błąd 401, więc pomiar P3 pomija 2 tokenizery.
8. **Pobieranie modeli.** Łącze dało prędkość 1,3 MB/s „[obserwacja: 2026-11-12, 17:41]”. Program `ollama` zatrzymał pobieranie 1 raz; skrypt ponawia pobieranie co 10 minut. Modele zajęły 12 GB na partycji `/mnt/windows`. Autor usunął 4 modele po pomiarze „[obserwacja: 2026-11-12, 20:41]”; surowe odpowiedzi modeli zostają w katalogu `results`.
9. **Stan modeli lokalnych.** Pomiar objął 4 modele lokalne z 4 planowanych: `llama3.2:3b`, `gemma3:4b`, Bielik 1.5B i Bielik 4.5B. Pobranie 4 modeli zajęło 2 h 42 min „[obserwacja: 2026-11-12, od 17:27 do 20:09]”.
10. **Parser bez poprawki Leo.** Gramatyka PK w pomiarze P2 ma wykładnik 1,77, a nie 1. Czas liniowy wymaga parsera z poprawką Leo.
11. **Sprawdzarka jest przybliżona.** Sprawdzarka zgłasza także fałszywe trafienia, na przykład przymiotnik w nazwie „małe litery”. Precyzja na próbie 60 trafień wynosi 95 %. Czułość jest nieznana.
12. **Podział aktów prawnych na zdania.** Akt składa się z jednostek redakcyjnych. Skrypt usuwa numery jednostek i dzieli tekst regułą interpunkcyjną, więc mediana długości zdania jest przybliżeniem.

7 Odtworzenie

- `make all`: testy, pomiary P1, P2, P3 i P5, agregaty pomiaru P4, rysunki i pliki PDF. Pomiary P3 i P5 pobierają dane z sieci.
- `make MEASURE_FLAGS=--offline all`: to samo bez sieci, z plików `results/p3_tokens.json` i `results/p5_corpus.json`.
- `python scripts/probe.py ollama MODEL`: pełna sonda na modelu lokalnym; skrypt pomija zapytania, które plik wyników już zawiera.
- `python scripts/probe.py claude MODEL --subset gray --samples 2`: sonda toru Claude.

Surowe odpowiedzi modeli zawierają pliki `results/probe_*.jsonl`, a dzienniki biegów zawiera katalog `results/logs`.