Polszczyzna kontrolowana jako metoda redukcji złożoności obliczeniowej w AI

Ujęcie logiczno-mnogościowe oraz refleksja filozoficzna
w świetle hipotezy Sapira-Whorfa

Maciej Szulia
maciej.szulia@gmail.com

listopad 2026

Streszczenie

Praca bada tezę, że Polszczyzna Kontrolowana (PK) zmniejsza złożoność obliczeniową pracy z tekstem. W części formalnej język jest parą: zbiór zdań i relacja interpretacji. Reguła PK jest operatorem, który usuwa zdania albo usuwa odczytania; operatory są przemienne. Liczba odczytań zdania jest iloczynem po miejscach wyboru. Praca dowodzi twierdzenia granicznego. Spójność zbioru wymagań bez przeczeń jest rozstrzygalna w czasie liniowym. Reguła C5 dopuszcza 1 przeczenie w zdaniu, a 1 przeczenie wystarcza do NP-zupełności. Część pomiarowa zawiera 5 pomiarów. Zdanie z 8 frazami przyimkowymi ma 4862 odczytania, a zdanie PK ma 1 odczytanie. PK wydłuża tekst: mediana narzutu wynosi 37 % tokenów. Sonda zadaje 5 modelom językowym pytania o sytuacje, w których odczytania zdania się różnią. Modele toru Claude odczytują zdania PK zgodnie z kluczem w co najmniej 91 % przypadków. Modele lokalne, które mają od 1,6 do 3,9 mld parametrów włącznie, osiągają od 54 % do 74 % włącznie. Konwencja niezgodna z nawykiem językowym działa na model dopiero z legendą. Akty prawne mają od 43 do 71 trafień sprawdzarki na 1000 słów włącznie. Część filozoficzna opisuje PK jako zestaw kategorii obowiązkowych i rozdziela hipotezę Sapira-Whorfa dla modelu językowego na 3 tezy. Wniosek: PK zmniejsza koszt wyboru odczytania i koszt wnioskowania, a zwiększa koszt przejścia tekstu przez model.

Słowa kluczowe: język kontrolowany; niejednoznaczność; złożoność obliczeniowa; klauzule Horna; modele językowe; hipoteza Sapira-Whorfa.

1 Wprowadzenie

Tekst, według którego ktoś działa, ma mieć 1 znaczenie. Polska gramatyka zostawia czytelnikowi wybór w stałych miejscach: brak rodzajników, swobodny szyk, dopełniacz, spójniki, granice przedziałów. Zdanie „Dzieci do 3 lat wchodzą bezpłatnie.” ma 2 odczytania: jedno obejmuje dziecko, które ma mniej niż 3 lata; drugie obejmuje dziecko, które ma mniej niż 4 lata.

Polszczyzna Kontrolowana, w skrócie PK, zamyka te miejsca wyboru [49]. PK w wersji 0.1 to zwykła polszczyzna oraz 32 numerowanych reguł w 5 grupach. Standard ma także moduł F dla raportów i listę słów kluczowych wymagań. Wzorami PK są angielski standard ASD-STE100 [3], słowa kluczowe RFC 2119 [7], notacja EARS [32] i polskie „Zasady techniki prawodawczej” [60].

Czytelnikiem tekstu bywa model językowy. Model wykonuje instrukcję, streszcza regulamin i sprawdza wymaganie. Praca bada tezę z tytułu: PK zmniejsza złożoność obliczeniową pracy z tekstem. Praca rozdziela tę tezę na 4 pytania.

(i) Jak zapisać PK w języku logiki i teorii mnogości?

(ii) Które koszty obliczeniowe PK zmniejsza, a które koszty PK zwiększa?

(iii) Ile wynosi narzut długości PK i jak modele językowe odczytują zdania PK?

(iv) Co PK mówi o hipotezie Sapira-Whorfa dla człowieka i dla modelu językowego?

Odpowiedzi w skrócie. Język jest parą: zbiór zdań i relacja interpretacji. Reguła PK jest operatorem, który usuwa zdania albo usuwa odczytania (sekcja 3). PK zmniejsza koszt 3 mechanizmami: zwija zbiór odczytań, ogranicza rozmiar zdania i daje zdaniu lokalność (sekcja 4). PK ma 1 koszt: tekst rośnie. Mediana narzutu wynosi 37 % tokenów (sekcja 6). Spójność zbioru wymagań bez przeczeń jest rozstrzygalna w czasie liniowym. Reguła C5 dopuszcza 1 przeczenie w zdaniu, a 1 przeczenie wystarcza do NP-zupełności (twierdzenie 4.3). Wynik pomiaru na modelach językowych podaje sekcja 6.4. Refleksję filozoficzną zawiera sekcja 7.

Status wyniku. Twierdzenia o parsowaniu, o kodowaniu i o klauzulach Horna są znane; praca przywołuje źródła. Wkładem pracy są: model mnogościowy reguł PK, klasyfikacja 32 reguł, twierdzenie graniczne o 1 przeczeniu, zbiór 44 pozycji testowych, sprawdzarka reguł oraz 5 pomiarów. Pomiary mają ograniczony zasięg; sekcja 8 wymienia zagrożenia dla trafności. Praca opisuje PK 0.1 i nie ocenia innych standardów.

Konwencje tekstu. Autor napisał tę pracę w PK. Legenda: „lub” znaczy co najmniej 1 z członów; „albo” znaczy dokładnie 1 z członów. Część dziesiętną liczby oddziela przecinek. Cytat, przykład zdania zwykłego i tytuł stoją w cudzysłowie; taki fragment leży poza PK. Każda liczba w tekście pochodzi ze skryptu `scripts/measure.py`. Sprawdzarka z sekcji 4.5 skontrolowała tekst pracy; wynik podaje tabela 5.

2 Stan wiedzy

Języki kontrolowane. Język kontrolowany to podzbiór języka naturalnego z ograniczoną gramatyką i ograniczonym słownictwem. Kuhn opisał 100 języków kontrolowanych opartych na angielskim i zaproponował klasyfikację PENS [28]. Klasyfikacja PENS ocenia 4 cechy: precyzję, ekspresywność, naturalność i prostotę. Kuhn stwierdza o językach klasy P^1, czyli o językach naturalnych, że automatyczna interpretacja jest problemem „AI-zupełnym”. Precyzja języka decyduje więc o koszcie interpretacji.

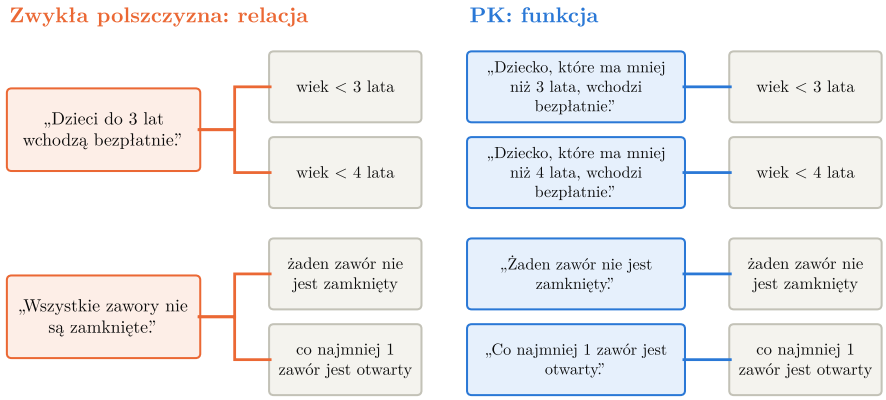
Języki kontrolowane mają 2 rodowody. Pierwszy rodowód to czytelność dla człowieka: „Basic English” Ogdena [37] i przewodnik AECMA z roku 1986, z którego powstał standard ASD-STE100 [3]. Drugi rodowód to interpretacja przez maszynę: Attempto Controlled English ma gramatykę formalną i tłumaczenie na logikę pierwszego rzędu [17]. PK 0.1 należy do pierwszego rodowodu. Standard PK 0.1 składa się z reguł zapisanych słowami i nie zawiera gramatyki formalnej. W klasyfikacji PENS autor umieszcza PK 0.1 w klasie P^2: język ma mniej niejednoznaczności niż język naturalny i nie ma podstawy formalnej.

Kontekst polski. Polska tradycja zna reguły redagowania tekstów prawnych [60] i ruch prostego języka; norma ISO 24495-1 opisuje prosty język [21]. Prosty język służy łatwemu zrozumieniu, a PK służy jednemu znaczeniu. Ziembiński opisuje amfibolię, czyli wieloznaczność składniową zdania [61]. Przybyszewski zbadał zdania przeczące z kwantyfikatorem ogólnym [42]. Kapłański opisał kontrolowaną angielszczyznę jako interfejs baz wiedzy [24]. Autor nie znalazł opublikowanego standardu kontrolowanej polszczyzny ogólnego przeznaczenia. Przegląd objął wyszukiwarki naukowe w listopadzie 2026 r. i ma ograniczony zasięg.

Złożoność a kształt języka. Church i Patil pokazali, że liczba rozbiorów zdania z ciągiem fraz przyimkowych rośnie jak liczby Catalana [10]. Earley podał algorytm parsowania gramatyk

PK zamienia relację interpretacji w funkcję: 2 zdania mają 4 znaczenia, 4 zdania PK mają po 1 znaczeniu

Zdania (po lewej) i znaczenia (po prawej); linia łączy zdanie ze znaczeniem zdania



Źródło: przykłady reguł D2 i C4 ze standardu PK 0.1; n = 2 zdania zwykłe, 4 zdania PK.

Rysunek 1: Teoria mnogości: relacja interpretacji zwykłej polszczyzny i funkcja, do której dąży PK.

bezkontekstowych w czasie rzędu n^3, a dla gramatyk jednoznacznych w czasie rzędu n^2 [13]. Knuth zdefiniował gramatyki LR(k), które parser czyta w czasie liniowym [27]; Leo rozszerzył algorytm Earleya na czas liniowy dla każdej gramatyki LR(k) [30]. Barton wykazał, że parsowanie gramatyk ID/LP, które opisują swobodny szyk, jest NP-zupełne [5]. Pratt-Hartmann i Third zbadali fragmenty języka angielskiego: problem spełnialności przechodzi od czasu wielomianowego do nierozstrzygalności, gdy fragment dostaje kolejne konstrukcje [40, 41]. Wyniki te pokazują wspólną zasadę: zakres dopuszczonych konstrukcji wyznacza klasę złożoności.

Niejednoznaczność a modele językowe. Zbiór AmbigQA zawiera pytania z więcej niż 1 odpowiedzią [34]. Liu i współautorzy zbudowali zbiór AmbiEnt i stwierdzili, że rozpoznanie niejednoznaczności jest dla modeli trudne [31]. Farquhar i współautorzy mierzą niepewność modelu entropią liczoną na poziomie znaczeń [14]. Piantadosi, Tily i Gibson bronią niejednoznaczności: kontekst rozstrzyga znaczenie, więc język zyskuje krótsze formy [39]. Wynik Piantadosiego wyznacza cenę PK: tekst bez oparcia w kontekście jest dłuższy.

3 Model logiczno-mnogościowy

3.1 Język jako para

Definicja 3.1. Niech W oznacza zbiór sytuacji. *Znaczenie* to podzbiór zbioru W. Zbiór znaczeń to $M = \mathcal{P}(W)$. *Język* to para (L,R): L jest zbiorem zdań, a $R \subseteq L \times M$ jest *relacją interpretacji*.

Definicja 3.2. *Zbiór odczytań* zdania s to $[\![s]\!] = \{m \in M : (s,m) \in R\}$. *Stopień niejednoznaczności* zdania s to liczba $a(s) = |[\![s]\!]|$. Zdanie s jest *jednoznaczne*, gdy $a(s) = 1$.

Język (L,R) jest jednoznaczny dokładnie wtedy, gdy relacja R jest funkcją z L do M. Zwykła polszczyzna jest relacją, która nie jest funkcją. Rysunek 1 pokazuje 2 zdania zwykłe z 4 odczytaniami i 4 zdania PK, z których każde ma 1 odczytanie.

3.2 Reguła jako operator

Standard PK zawiera reguły 2 rodzajów. Reguła pierwszego rodzaju zabrania konstrukcji: reguła A3 zabrania zaimka, reguła B5 zabrania imiesłowu. Reguła drugiego rodzaju zostawia zdanie i ustala odczytanie. Według reguły B2 pierwszy rzeczownik jest podmiotem. Według reguły C1 słowo „lub" znaczy co najmniej 1 człon.

Definicja 3.3. *Ograniczenie* to operator $\rho_\varphi(L,R) = (L \cap \varphi,\ R \cap (\varphi \times M))$ dla zbioru zdań φ. *Konwencja* to operator $\kappa_K(L,R) = (L,\ R \cap K)$ dla relacji $K \subseteq L \times M$.

Stwierdzenie 3.1. *Każde ograniczenie i każda konwencja zmniejsza język, zachowuje zawieranie i jest idempotentna. Każde 2 operatory są przemienne. Złożenie reguł $r_1, \ldots, r_n$ daje język*

$$L' = L \cap \bigcap_i \varphi_i, \qquad R' = R \cap \bigcap_j K_j \cap (L' \times M).$$

Dowód. Oba operatory są przecięciem z ustalonym zbiorem. Przecięcie zbiorów jest przemienne, łączne i idempotentne. □

Stwierdzenie 3.1 ma 2 skutki praktyczne. Kolejność stosowania reguł PK nie zmienia wyniku. Sprawdzenie tekstu rozkłada się na niezależne kontrole: 1 kontrola dla 1 reguły.

Cel standardu ma w modelu 2 warunki. Warunek spójności: $[\![s]\!]' \neq \emptyset$ dla każdego $s \in L'$, czyli konwencje zostawiają zdaniu co najmniej 1 odczytanie. Warunek jednoznaczności: $|[\![s]\!]'| \leq 1$ dla każdego $s \in L'$. Przy obu warunkach relacja R' jest funkcją.

Uwaga 3.1 (status celu)**.** Standard PK 0.1 formułuje cel słowami: czytelnik, który zna konwencję, odczytuje każde zdanie w 1 sposób. Cel jest hipotezą standardu. Numerowane reguły PK 0.1 celu nie gwarantują. Zdanie „Operatorowi NIE WOLNO włączyć pompy P1 i pompy P2." spełnia każdą regułę numerowaną. Zdanie ma 2 odczytania: zakaz dotyczy każdej z 2 pomp albo zakaz dotyczy włączenia 2 pomp naraz. Zdanie „Każdy operator obsługuje dokładnie 1 pompę." także spełnia reguły i ma 2 odczytania zasięgu. Standard zamyka takie przypadki krokiem 7 kontroli, czyli testem 2 znaczeń. Test 2 znaczeń wymaga oceny znaczenia przez człowieka. Pozycje G1 i G2 zbioru testowego mierzą te 2 luki (sekcja 6.4).

3.3 Miejsca wyboru

Definicja 3.4. *Miejsce wyboru* zdania s to konstrukcja, która dopuszcza co najmniej 2 odczytania przy ustalonych odczytaniach reszty zdania. Miejsce wyboru i ma zbiór wariantów C_i. Miejsca wyboru są *niezależne*, gdy każda kombinacja wariantów daje inne odczytanie.

Twierdzenie 3.1. *Jeżeli zdanie s ma k niezależnych miejsc wyboru, to $a(s) = \prod_{i=1}^{k} |C_i|$ oraz $\log_2 a(s) = \sum_{i=1}^{k} \log_2 |C_i|$. Zamknięcie miejsca wyboru i zmniejsza $\log_2 a(s)$ o $\log_2 |C_i|$ bitów.*

Dowód. Zbiór odczytań jest w bijekcji z iloczynem kartezjańskim $C_1 \times \cdots \times C_k$. □

Twierdzenie 3.1 tłumaczy, dlaczego reguły PK działają osobno. Każda reguła zamyka 1 typ miejsca wyboru i odejmuje stałą liczbę bitów. Miejsca wyboru bywają zależne; wtedy liczba odczytań jest mniejsza niż iloczyn. Pomiar P1 liczy odczytania dokładnie dla 4 konstrukcji (tabela 1, rysunek 6).

Według reguły B8 zdanie opisu ma co najwyżej 25 słów. Samo ograniczenie długości nie usuwa niejednoznaczności. Liczba nawiasowań binarnych ciągu 25 słów to liczba Catalana $C_{24} = 1\,289\,904\,147\,324$. Zbiór odczytań jest więc skończony, a górna granica liczby odczytań ma rząd 10^{12}. Jednoznaczność dają dopiero pozostałe reguły.

3.4 Strefa szara

Definicja 3.5. *Strefa szara* zdania s to zbiór $G(s) = \bigcup[\![s]\!] \setminus \bigcap[\![s]\!]$.

Strefa szara zawiera sytuacje, w których odczytania dają różną wartość logiczną. Poza strefą szarą odczytania są zgodne. Strefa szara jest pusta dokładnie wtedy, gdy każde 2 odczytania zdania są równe; dla zdania jednoznacznego $G(s) = \emptyset$.

Przykład 3.1. Zdanie „Dzieci do 3 lat wchodzą bezpłatnie.” ma odczytania $m_1 = \{w : \text{wiek} < 3\}$ i $m_2 = \{w : \text{wiek} < 4\}$. Strefa szara to $\{w : 3 \leq \text{wiek} < 4\}$. Dziecko, które ma 3 lata i 5 miesięcy, leży w strefie szarej.

Model strefy szarej odpowiada nadwartościowaniu Fine'a [15]: zdanie jest nadprawdziwe w $\bigcap[\![s]\!]$ i nadfałszywe poza $\bigcup[\![s]\!]$. Rysunek 2 pokazuje strefy szare 5 pozycji testowych, a rysunek 3 pokazuje ten sam obiekt w tablicach prawdy. Pomiar P4 opiera się na strefie szarej: sonda pyta model o sytuację, w której odczytania się różnią.

3.5 Moc zbioru odczytań

Zbiór odczytań ma w modelu 3 możliwe moce.

- **Moc 1.** Zdanie jest jednoznaczne. Taki stan jest celem PK.
- **Moc skończona większa niż 1.** Źródłem jest składnia albo słownik: zasięg określenia, zaimek, spójnik, granica przedziału. Lista zakończona skrótem „itp.” oznacza nadzbiór zbioru wymienionych elementów; zdanie nie wskazuje, który nadzbiór. Dla dziedziny o u elementach i listy o k elementach zdanie ma 2^{u-k} odczytań; dla $u = 10$ i $k = 2$ zdanie ma 256 odczytań.
- **Moc continuum.** Słowo nieostre, na przykład „regularnie”, dopuszcza każdy próg z przedziału liczb rzeczywistych. Zbiór dopuszczalnych uściśleń jest nieprzeliczalny [15]. Reguła A5 każe wybrać 1 próg i zapisać próg liczbą z jednostką.

Osobną klasę tworzy deiksa. Znaczenie słowa „jutro” jest funkcją kontekstu; Kaplan nazywa taką funkcję charakterem wyrażenia [23]. Reguła D3 wymaga daty. Zdanie z datą ma stały charakter: znaczenie zdania jest takie samo w każdym dniu czytania.

3.6 Klasyfikacja reguł

Autor przypisał każdej z 32 reguł 3 cechy: rodzaj operatora, klasę sprawdzarki i mechanizm redukcji kosztu. Klasyfikację zawiera plik `data/rules.csv`; rysunek 4 pokazuje wynik. Ograniczeniem jest 21 reguł. Ograniczenie i konwencję łączy 10 reguł. Samą konwencją jest 1 reguła: reguła E6, która każe ujawnić konwencje w legendzie. Klasyfikacja jest oceną autora i nie ma drugiego oceniającego.

4 Złożoność obliczeniowa

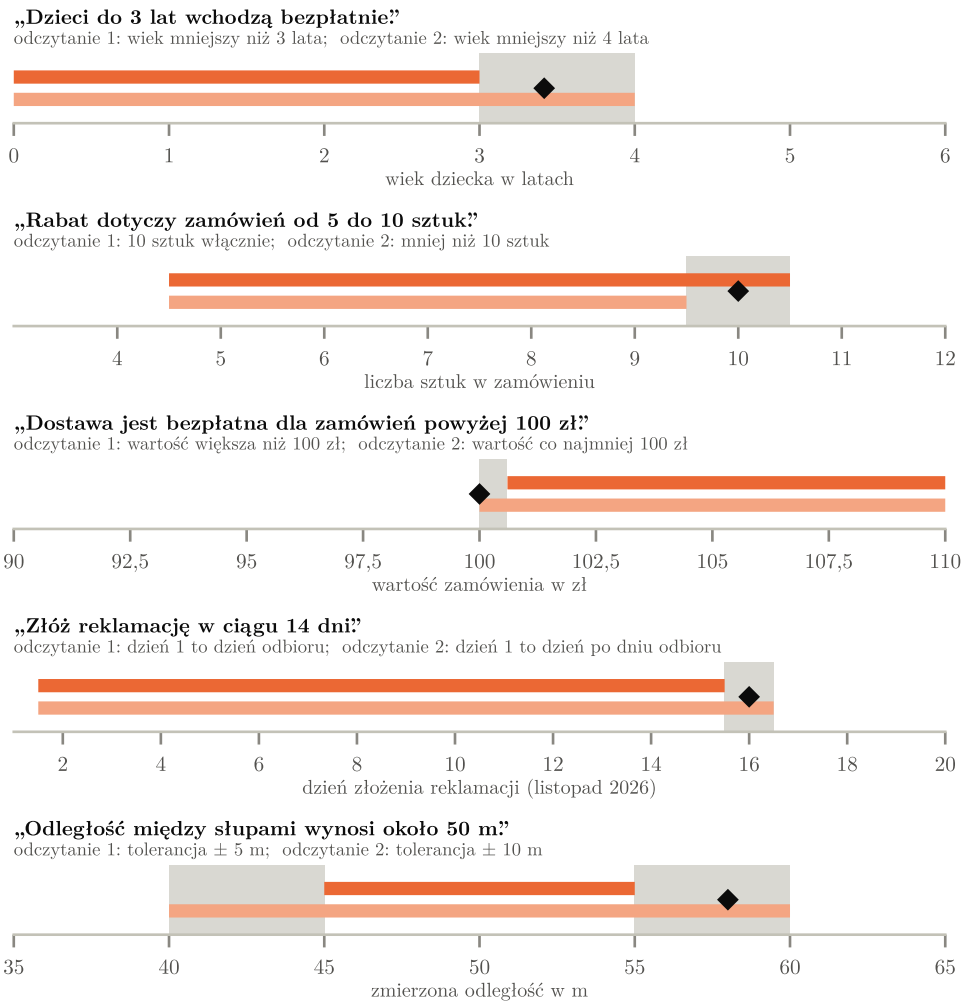
4.1 Zadania czytelnika i mechanizmy PK

Czytelnik tekstu wykonuje 4 zadania. Zadanie PARSUJ wyznacza zbiór odczytań zdania. Zadanie WYBIERZ wskazuje odczytanie, które zamierzył autor. Zadanie SPRAWDŹ rozstrzyga, czy tekst spełnia reguły. Zadanie WNIOSKUJ rozstrzyga, czy zbiór zdań jest spójny i co ze zbioru wynika. PK zmienia koszt tych zadań 3 mechanizmami.

- **M1, zwinięcie zbioru odczytań.** Reguła zmniejsza liczbę $a(s)$ do wartości 1. Zadanie WYBIERZ znika.

2 odczytania zdania zgadzają się poza wąską strefą szarą; sonda pyta o sytuację ze strefy szarej

Pasek górny: odczytanie 1. Pasek dolny: odczytanie 2. Tło szare: strefa szara. Romb: sytuacja sondy



Źródło: data/items.csv, pozycje D2a, D2b, D2c, D4a, D6b; n = 5 z 44 pozycji.

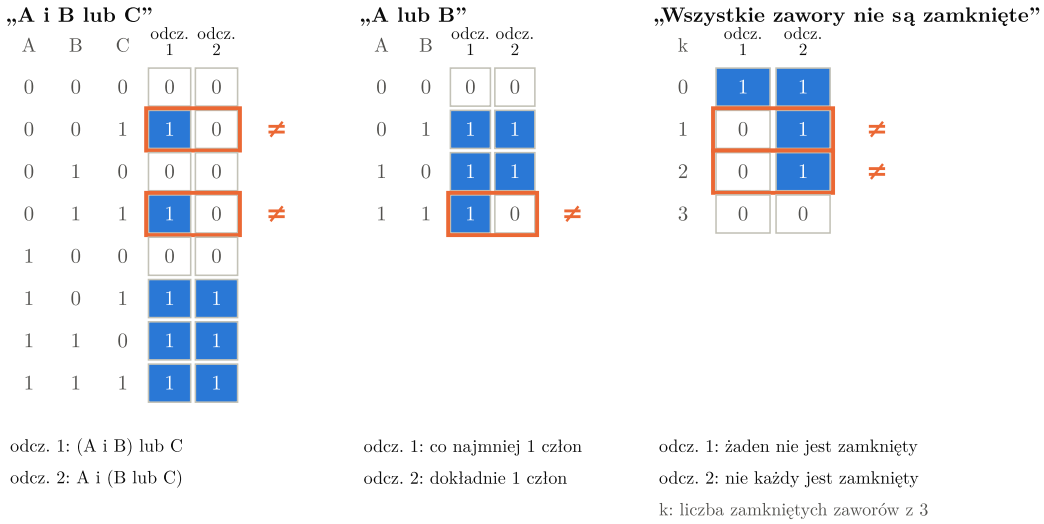
Rysunek 2: Semantyka: 2 odczytania jako zbiory na osi liczbowej i strefa szara, w której odczytania się różnią.

- **M2, ograniczenie rozmiaru.** Reguły B8, B4, C2 i C5 ograniczają liczbę słów, liczbę rzeczowników w ciągu, mieszanie spójników i liczbę przeczeń. Koszt zadania PARSUJ dla 1 zdania ma stałą górną granicę, więc koszt dla tekstu rośnie liniowo z liczbą zdań.
- **M3, lokalność.** Reguły A2, A3, D3 i E4 usuwają zaimek, deiksę i odesłanie bez numeru. Czytelnik interpretuje zdanie bez przeszukiwania reszty tekstu. Tekst jest koniunkcją zdań ze wspólnym słownikiem nazw.

Kosztem PK jest długość: nazwa zastępuje zaimek, liczba z jednostką zastępuje słowo nieostre, a 2 zdania zastępują imiesłów.

2 odczytania jednego zdania dają różną wartość logiczną w 2 z 8, w 1 z 4 i w 2 z 4 sytuacji

Tablice prawdy: 1 oznacza prawdę. Ramka i znak ≠: wiersz, w którym odczytania się różnią

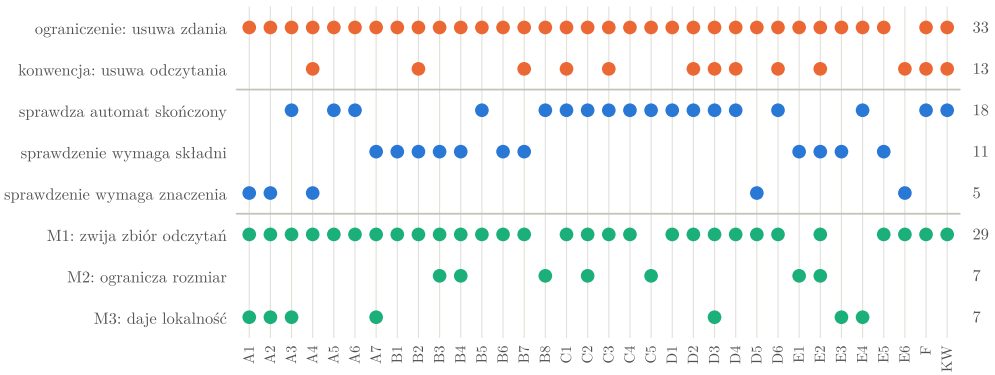


Źródło: wyliczenie w scripts/figures.py; zdania z reguł C2, C1 i C4 standardu PK 0.1.

Rysunek 3: Logika: tablice prawdy 2 odczytań dla reguł C2, C1 i C4.

16 z 32 reguł PK sprawdza automat skończony; 11 reguł wymaga analizy składni, 5 reguł wymaga znaczenia

Kropka: reguła ma cechę. Liczba po prawej: liczba reguł z cechą (32 reguły, moduł F i słowa kluczowe KW)



Źródło: data/rules.csv, klasyfikacja autora na podstawie tekstu standardu PK 0.1; n = 34 wierszy.

Rysunek 4: Klasyfikacja reguł PK 0.1 według rodzaju operatora, klasy sprawdzarki i mechanizmu redukcji kosztu.

4.2 Zadanie PARSUJ

Dla gramatyki bezkontekstowej algorytm Earleya działa w czasie rzędu n^3; dla gramatyki jednoznacznej w czasie rzędu n^2 [13]. Dla gramatyki LR(k) istnieje parser liniowy [27, 30]. Swobodny szyk podnosi koszt: problem rozpoznawania dla gramatyk ID/LP jest NP-zupełny [5]. Reguła B2 ustala szyk: podmiot, orzeczenie, dopełnienie. Reguła B6 stawia określenie przy słowie określanym.

Pomiar P2 porównuje 2 gramatyki modelowe. Gramatyka pierwsza pozwala przyłączyć frazę przyimkową do czasownika albo do rzeczownika, który stoi wcześniej. Gramatyka druga, zgodna z regułą B6, przyłącza frazę do rzeczownika bezpośrednio przed frazą. Obie gramatyki generują te same ciągi słów. Wynik podaje sekcja 6.2. Gramatyki są modelami 1 konstrukcji i nie opisują całej polszczyzny.

4.3 Zadanie WYBIERZ

Twierdzenie 4.1. *Niech Z oznacza zamierzone odczytanie zdania s, czyli zmienną losową o rozkładzie P na zbiorze $[\![s]\!]$. Każda strategia pytań z odpowiedzią „Tak" albo „Nie", która zawsze wskazuje Z, zadaje średnio co najmniej $H(Z) = -\sum_m P(m) \log_2 P(m)$ pytań. Istnieje strategia, która zadaje średnio mniej niż $H(Z) + 1$ pytań.*

Dowód. Strategia pytań jest drzewem binarnym, czyli kodem prefiksowym dla zbioru $[\![s]\!]$. Oba oszacowania wynikają z twierdzenia Shannona o kodowaniu bez szumu [47]. □

Wielkość $H(Z)$ jest brakiem informacji w zdaniu. Czytelnik pobiera brakujące bity z kontekstu, z pytania do autora albo z własnego domysłu. Dla zdania PK brak wynosi 0 bitów. Dla zdania z 2 równie prawdopodobnymi odczytaniami brak wynosi 1 bit. Czytelnik, który zgaduje, myli się wtedy w 50 % przypadków przy każdej strategii zgadywania.

4.4 Zadanie WNIOSKUJ

Praca definiuje rdzeń zdaniowy PK dla wymagań. Rdzeń obejmuje wzór „Jeżeli W, to D." z reguły C3, zakaz mieszania spójników z reguły C2 i limit przeczeń z reguły C5.

Definicja 4.1. Niech A oznacza zbiór zdań prostych twierdzących, czyli *atomów*. *Literał* to atom albo atom z przeczeniem. Język PK_0 zawiera zdania 2 postaci:

„Jeżeli l_1 i … i l_k, to a." „Jeżeli l_1 i … i l_k, to konflikt."

gdzie $k \geq 0$, każde l_i jest literałem, a a jest atomem. Zdanie drugiej postaci zapisuje 2 wymagania dla 1 działania: „MUSI" oraz „NIE WOLNO". Język PK_0^j zawiera zdania, w których poprzednik ma co najwyżej j przeczeń. Zbiór zdań Γ jest *spójny*, gdy co najmniej 1 wartościowanie atomów spełnia każde zdanie zbioru Γ; zdanie drugiej postaci jest spełnione, gdy poprzednik jest fałszywy.

Twierdzenie 4.2. *Spójność zbioru zdań języka PK_0^0 jest rozstrzygalna w czasie liniowym względem łącznej długości zdań.*

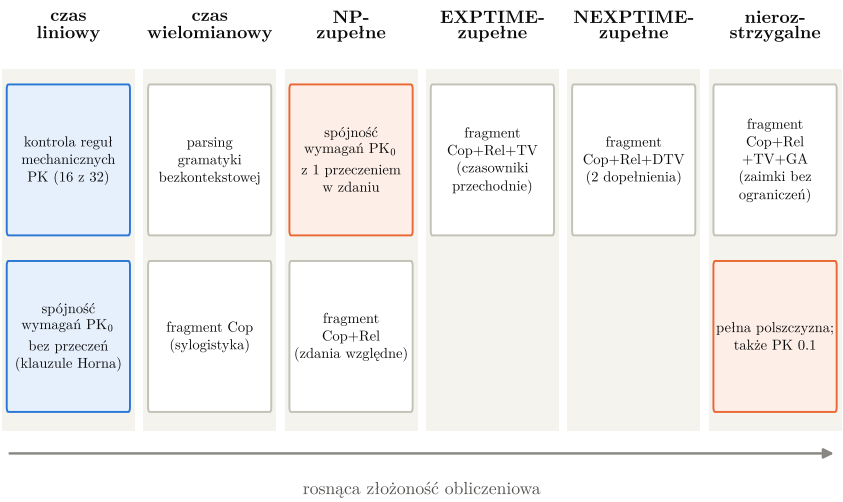
Dowód. Zdanie „Jeżeli a_1 i … i a_k, to a." jest klauzulą $\neg a_1 \vee \cdots \vee \neg a_k \vee a$. Zdanie z konfliktem jest klauzulą $\neg a_1 \vee \cdots \vee \neg a_k$. Każda klauzula ma co najwyżej 1 literał dodatni, czyli jest klauzulą Horna. Algorytm Dowlinga i Galliera rozstrzyga spełnialność formuły Horna w czasie liniowym [12]. □

Twierdzenie 4.3. *Spójność zbioru zdań języka PK_0^1 jest problemem NP-zupełnym.*

Dowód. Problem należy do klasy NP: świadkiem jest wartościowanie. NP-trudność wynika z redukcji problemu 3-SAT [11]. Niech C będzie klauzulą o 3 literałach nad atomami x, y, z. Redukcja zależy od liczby literałów dodatnich w klauzuli C.

1 przeczenie w zdaniu warunkowym przenosi spójność zbioru wymagań z czasu liniowego do klasy problemów NP-zupełnych

Niebieski i pomarańczowy: wyniki tej pracy. Biały: wyniki znane, fragmenty języka angielskiego według Pratta-Hartmanna i Thirda



Źródło: twierdzenia 4.2 i 4.3 tej pracy; Dowling i Gallier (1984); Earley (1970); Pratt-Hartmann i Third (2006).

Rysunek 5: Teoria złożoności: położenie problemów związanych z PK wśród klas złożoności.

Klauzula C	Zdania języka PK_0^1
$\neg x \vee \neg y \vee \neg z$	Jeżeli x i y i z, to konflikt.
$\neg x \vee \neg y \vee z$	Jeżeli x i y, to z.
$\neg x \vee y \vee z$	Jeżeli x i nie y, to z.
$x \vee y \vee z$	Jeżeli nie x, to u. Jeżeli u i nie y, to z.

W 3 pierwszych wierszach zdanie jest równoważne klauzuli. W wierszu czwartym u jest nowym atomem, a zdania dają klauzule $x \vee u$ oraz $\neg u \vee y \vee z$. Jeżeli wartościowanie spełnia $x \vee y \vee z$, to rozszerzenie $u = \neg x$ spełnia obie klauzule. W drugą stronę rezolucja względem u daje $x \vee y \vee z$. Każde zdanie ma co najwyżej 1 przeczenie, a liczba zdań jest co najwyżej 2 razy większa niż liczba klauzul. □

Skrypt sprawdził redukcję na 400 losowych formułach, z których każda ma co najwyżej 6 zmiennych: pełne wyliczenie wartościowań dało zgodną odpowiedź w każdym przypadku. Twierdzenie 4.3 zgadza się z dychotomią Schaefera [45]: zbiór klauzul Horna z klauzulą $x \vee u$ leży poza każdą klasą łatwą.

Uwaga 4.1 (znaczenie dla standardu)**.** Reguła C5 dopuszcza 1 przeczenie w zdaniu, a reguła C3 zaleca wzór „Jeżeli nie W, to D2.” dla przypadku przeciwnego. Zbiór wymagań zgodny z PK 0.1 jest więc zbiorem zdań języka PK_0^1. Zbiór bez przeczeń w poprzednikach leży po stronie czasu liniowego. Zbiór z 1 przeczeniem w poprzedniku leży po stronie NP-zupełności. NP-zupełność opisuje przypadek najgorszy; programy rozstrzygające spełnialność radzą sobie z praktycznymi zbiorami wymagań. Pełna PK 0.1 nie ogranicza ekspresywności polszczyzny, więc wnioskowanie w pełnej PK jest nierozstrzygalne tak samo jak w logice pierwszego rzędu. Rysunek 5 zestawia wyniki z fragmentami języka angielskiego [41].

4.5 Zadanie SPRAWDŹ

Reguły PK różnią się kosztem kontroli. Autor wyróżnił 3 klasy sprawdzarek (rysunek 4). Automat skończony nad ciągiem słów rozstrzyga 16 z 32 reguł: listę słów zakazanych, długość zdania, liczbę przeczeń, zapis granicy. Analizy składni wymaga 11 reguł, na przykład szyk z reguły B2 i zasięg z reguły B6. Oceny znaczenia wymaga 5 reguł, na przykład reguła A1: 1 termin dla 1 pojęcia.

Plik `src/pklint.py` zawiera sprawdzarkę z 21 kontrolami. Każda kontrola jest wyrażeniem regularnym nad słowami 1 zdania, więc sprawdzarka działa w czasie liniowym. Sprawdzarka wskazuje kandydatów; ocenę kończy człowiek. Na zbiorze testowym sprawdzarka wykrywa 26 z 44 zdań zwykłych i nie zgłasza żadnego z 88 zdań PK. Pozostałe 18 zdań zwykłych wymaga analizy składni albo znaczenia.

4.6 Koszt w modelu językowym

Koszt przejścia tekstu przez transformator zależy od liczby tokenów n: warstwa uwagi wykonuje pracę rzędu n^2 [52]. Rozstrzygnięcie niejednoznaczności tej pracy nie zmienia. Merrill i Sabharwal wykazali, że transformator o precyzji logarytmicznej liczy tylko funkcje z klasy TC^0 [33]. Model przenosi więc trudniejsze obliczenia do kolejnych generowanych tokenów. Zdanie, które wymaga wyboru odczytania, dokłada modelowi pracy; zdanie jednoznaczne tej pracy nie dokłada. Praca nie mierzy tego efektu wewnątrz modelu; pomiar P4 mierzy zachowanie modelu na wyjściu.

Twierdzenie 4.4. *Niech tekst zwykły ma n tokenów, a tekst PK ma $(1+\delta)n$ tokenów. Niech czytelnik odczytuje tekst zwykły błędnie z prawdopodobieństwem p, a tekst PK z prawdopodobieństwem e. Niech po błędnym odczytaniu zadanie wraca do autora i czytelnik czyta tekst od nowa, a próby są niezależne. Oczekiwany koszt odczytania w tokenach wynosi $n/(1-p)$ dla tekstu zwykłego i $(1+\delta)n/(1-e)$ dla tekstu PK. Tekst PK jest tańszy dokładnie wtedy, gdy*

$$p > 1 - \frac{1-e}{1+\delta}. \tag{1}$$

Dowód. Liczba prób ma rozkład geometryczny o wartości oczekiwanej $1/(1-p)$ albo $1/(1-e)$. Nierówność (1) wynika z porównania 2 kosztów. □

Dla $e = 0$ warunek (1) ma postać $p > \delta/(1+\delta)$. Model pomija koszt wykrycia błędu i koszt szkody; oba koszty przesuwają próg na korzyść PK. Model pomija także pracę autora. Autor pisze tekst 1 raz, a czytelnicy czytają tekst k razy, więc dodatkowa praca autora rozkłada się na k odczytów. Model językowy czyta instrukcję systemową przy każdym wywołaniu.

5 Metoda pomiarów

Praca zawiera 5 pomiarów. Pomiary P1 i P2 są obliczeniami na modelu formalnym. Pomiary P3 i P4 korzystają ze zbioru pozycji testowych. Pomiar P5 korzysta z korpusu tekstów.

5.1 Zbiór pozycji testowych

Zbiór ma 44 pozycji (plik `data/items.csv`, dodatek B). Pozycja zawiera 6 części: zdanie zwykłe, opis 2 odczytań, zdanie PK dla odczytania 1, zdanie PK dla odczytania 2 oraz 3 sondy. Sonda to sytuacja z pytaniem, na które odpowiedzią jest „Tak” albo „Nie”. Pierwsza sonda leży w strefie szarej: odczytanie 1 daje jedną odpowiedź, a odczytanie 2 daje odpowiedź przeciwną. Sondy druga i trzecia są kotwicami: oba odczytania dają odpowiedź „Tak” w kotwicy drugiej i odpowiedź „Nie” w kotwicy trzeciej. Kotwice sprawdzają, czy model rozumie zadanie.

Zdanie zwykłe w 16 pozycjach pochodzi z przykładów standardu PK 0.1. Standard powstał przed tą pracą, więc autor nie dobierał tych zdań pod wynik pomiaru. Pozostałe 28 pozycji napisał autor. Zbiór ma 3 rodzaje pozycji.

- **Przeredagowanie** (38 pozycji): zdanie PK jest innym ciągiem słów niż zdanie zwykłe.
- **Konwencja** (4 pozycje, reguły B2 i C1): zdanie PK dla odczytania 1 jest tym samym ciągiem słów co zdanie zwykłe. Odczytanie ustala konwencja, więc pozycja ma dodatkowy wariant z legendą.
- **Luka** (2 pozycje): zdanie zwykłe spełnia numerowane reguły PK i ma 2 odczytania (uwaga 3.1).

Każde zdanie PK w zbiorze przechodzi sprawdzarkę z sekcji 4.5. Zdanie PK o największej liczbie słów ma 15 słów.

5.2 Pomiary P1 i P2

Pomiar P1 liczy odczytania dokładnie. Funkcja `count_parses` liczy drzewa rozbioru zdania z k frazami przyimkowymi. Funkcja `bracketings` wylicza nawiasowania ciągu członów połączonych na przemian słowami „i” oraz „lub” i liczy różne funkcje logiczne. Funkcja `scope_orders` liczy różne porządki zasięgu kwantyfikatorów „każdy” i „pewien” ustawionych na przemian. Dla co najwyżej 4 kwantyfikatorów test sprawdza wynik semantycznie: wylicza każdą relację na dziedzinie o 2 elementach.

Pomiar P2 uruchamia parser Earleya na zdaniach o budowie: rzeczownik, czasownik, rzeczownik oraz k fraz przyimkowych, dla k od 0 do 40 włącznie. Zdanie ma wtedy od 3 do 83 słów włącznie. Operacją jest 1 próba wpisania stanu do tablicy parsera. Parser nie zawiera poprawki Leo [30]. Wykładnik wzrostu pochodzi z regresji liniowej logarytmu liczby operacji względem logarytmu liczby słów, dla zdań, które mają co najmniej 21 słów.

5.3 Pomiar P3: długość

Pomiar P3 liczy długość zdania zwykłego i 2 zdań PK w 6 miarach: słowa, znaki oraz tokeny 4 tokenizerów. Tokenizery `o200k_base` i `cl100k_base` pochodzą z biblioteki `tiktoken`; tokenizery modeli `Llama 3.2` i `Gemma 3` pochodzą z plików modeli. Tokenizery modeli Bielik wymagają zgody licencyjnej w serwisie Hugging Face, więc pomiar pomija tokenizery modeli Bielik. Narzut pozycji to iloraz: średnia długość 2 zdań PK podzielona przez długość zdania zwykłego, minus 1. Pomiar obejmuje 40 pozycji: przeredagowania i luki. Pozycje typu konwencja mają narzut 0 z definicji; kosztem konwencji jest legenda. Dla mediany narzutu skrypt liczy przedział ufności 95 % metodą bootstrap z 10 000 losowań.

5.4 Pomiar P4: sonda strefy szarej

Model językowy dostaje instrukcję systemową: „Odpowiadasz na pytania o znaczenie tekstu. Odpowiedz jednym słowem: Tak albo Nie.” Wiadomość zawiera tekst, sondę i powtórzone polecenie odpowiedzi 1 słowem. Tekstem jest zdanie zwykłe, zdanie PK dla odczytania 1 albo zdanie PK dla odczytania 2. Pozycja typu konwencja ma także 2 warianty z legendą. Razem pomiar ma 420 sond, czyli 408 różnych zapytań na model.

Pomiar ma 2 wykonane tory.

- **Tor lokalny.** Program `ollama` uruchamia model na procesorze komputera autora, z temperaturą 0. Skrypt odczytuje prawdopodobieństwa 20 najbardziej prawdopodobnych tokenów na pierwszej pozycji odpowiedzi. Wielkość $P(\text{Tak})$ to masa tokenów słowa „Tak” podzielona przez sumę mas tokenów słów „Tak” i „Nie”. Tor lokalny obejmuje każdą z 408 sond.

- **Tor Claude.** Polecenie `claude -p` wywołuje modele Haiku i Sonnet bez narzędzi, bez plików reguł autora i bez pamięci sesji; mediana zużycia to 687 tokenów wejściowych na wywołanie. Interfejs nie podaje prawdopodobieństw tokenów. Skrypt zadaje więc każdą sondę 2 razy i liczy udział odpowiedzi „Tak". Tor Claude obejmuje tylko sondy strefy szarej: 136 zapytań i 272 wywołania na model.

Plan przewidywał tor trzeci, przez serwis OpenRouter. Tor trzeci nie powstał. Zabezpieczenie komputera autora zablokowało odczyt klucza dostępu, a autor zostawił blokadę na czas pomiaru.

Niech q oznacza prawdopodobieństwo odczytania 1 w strefie szarej. Skrypt liczy 5 miar.

- **Niepewność** $H_2(q) = -q \log_2 q - (1-q) \log_2(1-q)$, w bitach, dla zdania zwykłego i średnio dla 2 zdań PK. Miara wymaga prawdopodobieństw, więc dotyczy toru lokalnego.
- **Sterowalność**: różnica q dla zdania PK odczytania 1 i q dla zdania PK odczytania 2. Wartość 1 oznacza pełne sterowanie; wartość 0 oznacza brak wpływu.
- **Trafność PK**: udział zdań PK, dla których model wybiera odczytanie zamierzone, czyli $q > 0{,}5$ dla odczytania 1 i $q < 0{,}5$ dla odczytania 2. Poziom przypadku wynosi 50 %.
- **Trafność kotwic**: udział kotwic z odpowiedzią zgodną z kluczem.
- **Rozbieżność czytelników**: udział pozycji, w których modele wybierają różne odczytania zdania zwykłego.

Dla niepewności skrypt wykonuje dokładny test znaków na pozycjach typu przeredagowanie. Test nie ma poprawki na liczbę modeli.

5.5 Pomiar P5: korpus

Korpus zawiera 5 aktów prawnych i 3 teksty pisane w PK. Akty prawne pochodzą z serwisu `api.sejm.gov.pl`: Konstytucja RP oraz teksty jednolite Kodeksu cywilnego, Kodeksu pracy, Prawa o ruchu drogowym i „Zasad techniki prawodawczej". Akty prawne nie są przedmiotem prawa autorskiego; repozytorium zapisuje adresy, sumy SHA-256 i wyniki zliczeń. Teksty PK to: standard PK 0.1, praca „Rachunek generatorów" tego samego autora oraz niniejsza praca.

Skrypt usuwa z aktu nagłówki stron i numery jednostek redakcyjnych. Sprawdzarka liczy trafienia każdej z 21 kontroli; miarą jest liczba trafień na 1000 słów. Trafienie wskazuje konstrukcję objętą regułą PK. Trafienie nie dowodzi, że zdanie ma 2 odczytania w kontekście aktu. Autor ocenił ręcznie losową próbę 60 trafień z aktów prawnych; próba nie obejmuje kontroli długości zdania. Ocenę wykonał 1 oceniający.

5.6 Powtarzalność

Polecenie `make all` uruchamia testy, pomiary P1, P2, P3 i P5, rysunki i budowę pliku PDF. Surowe odpowiedzi modeli leżą w plikach `results/probe_*.jsonl`; skrypt `scripts/measure.py` przelicza z tych plików każdą liczbę pomiaru P4. Ciągła integracja nie wywołuje modeli. Wagi modeli lokalnych identyfikuje nazwa z rejestru programu `ollama`; modele Claude nie są dostępne bez konta, więc tor Claude odtwarza tylko posiadacz konta.

6 Wyniki

6.1 P1: liczba odczytań

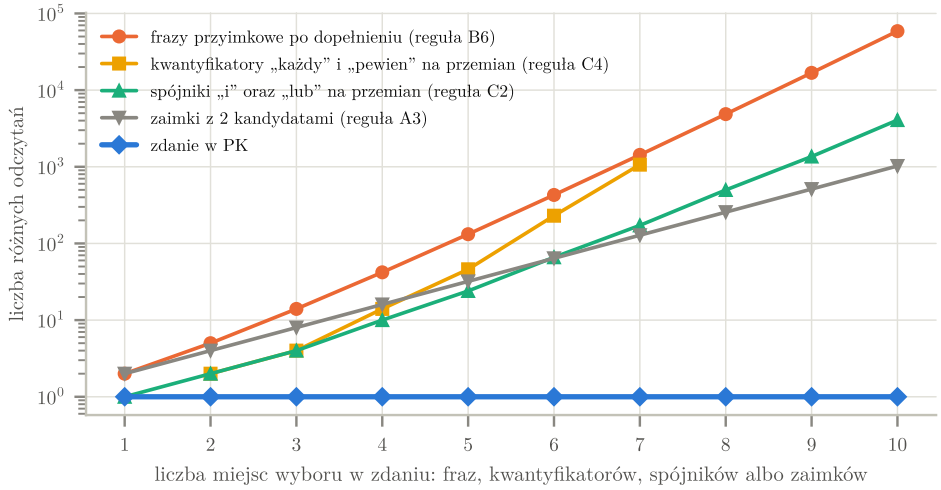
Tabela 1 i rysunek 6 podają liczbę odczytań dla 3 konstrukcji. Zdanie z 8 frazami przyimkowymi ma 4862 odczytania. Ciąg 11 członów połączonych na przemian słowami „i" oraz „lub" ma 16 796

Tabela 1: P1: liczba logicznie różnych odczytań zdania. Kolumna 2: k fraz przyimkowych po dopełnieniu. Kolumna 3: k spójników „i” oraz „lub” na przemian. Kolumna 4: $k+1$ kwantyfikatorów „każdy” i „pewien” na przemian.

k	frazy przyimkowe	spójniki	kwantyfikatory
1	2	1	2
2	5	2	4
3	14	4	14
4	42	10	46
5	132	24	230
6	429	66	1066
7	1430	172	

Liczba odczytań rośnie wykładniczo: 8 fraz przyimkowych daje 4862 odczytania, zdanie w PK ma 1 odczytanie

Liczba logicznie różnych odczytań zdania dla 4 konstrukcji; skala logarytmiczna



Źródło: results/p1_counts.json, dokładne wyliczenie funkcjami count_parses, scope_orders i bracketings z src/pkmodel.py.

Rysunek 6: Kombinatoryka: wzrost liczby odczytań z liczbą miejsc wyboru.

nawiasowań, które dają 4066 różnych funkcji logicznych. Zdanie z 4 kwantyfikatorami ma 24 porządki zasięgu, w tym 14 logicznie różnych. Wzrost jest wykładniczy w każdej z 3 konstrukcji. Zdanie PK ma 1 odczytanie przy każdej liczbie miejsc wyboru.

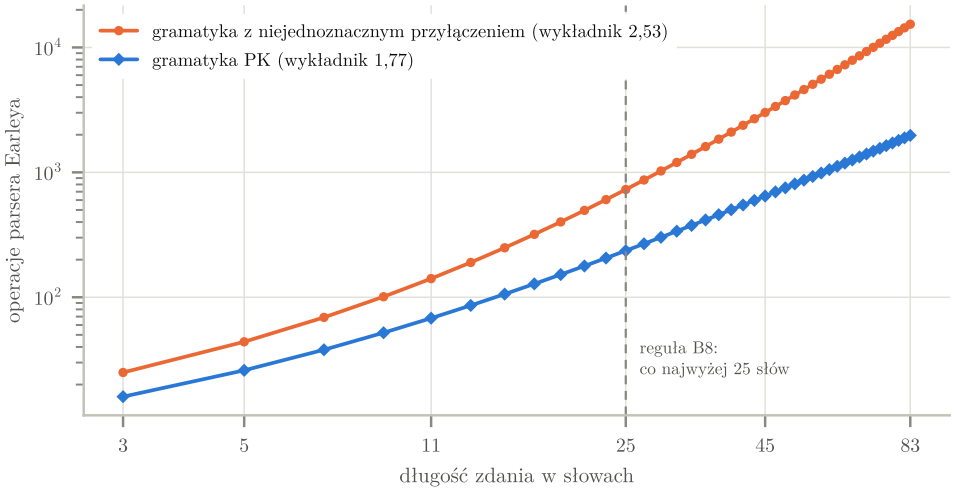
6.2 P2: operacje parsera

Rysunek 7 pokazuje liczbę operacji parsera. Dla zdania o 21 słowach parser wykonuje 496 operacji z gramatyką niejednoznaczną i 178 operacji z gramatyką PK. To samo zdanie ma 16 796 drzew rozbioru w gramatyce niejednoznacznej i 1 drzewo w gramatyce PK. Dla zdania o 83 słowach liczby operacji wynoszą 15 345 oraz 1976; iloraz to 7,8.

Dopasowany wykładnik wzrostu wynosi 2,53 dla gramatyki niejednoznacznej i 1,77 dla gramatyki PK. Oba wykładniki są mniejsze niż granice teoretyczne 3 i 2, bo zdania pomiaru mają co najwyżej 83 słów. Gramatyka PK jest jednoznaczna i ma rekursję prawostronną. Parser Earleya bez poprawki Leo przetwarza taką gramatykę w czasie kwadratowym; z poprawką Leo czas jest liniowy [30]. Pomiar potwierdza kierunek zmiany i nie potwierdza czasu liniowego.

Parser wykonuje dla gramatyki PK 7,8 razy mniej operacji przy 83 słowach; wykładnik wzrostu spada z 2,53 do 1,77

Zmierzona liczba operacji rozpoznawania zdań „rzeczownik czasownik rzeczownik” z k frazami przyimkowymi; obie skale logarytmiczne



Źródło: results/p2_parser.json, funkcja earley z src/pkmodel.py; n = 41 zdań; wykładnik dopasowany dla zdań od 21 słów.

Rysunek 7: Teoria złożoności: zmierzona liczba operacji parsera Earleya dla gramatyki niejednoznacznej i dla gramatyki PK.

W zakresie reguły B8 przewaga gramatyki PK w liczbie operacji jest umiarkowana: dla zdania o 25 słowach iloraz wynosi 3,1. Główną korzyścią w tym zakresie jest liczba drzew: 1 drzewo zamiast 208 012 drzew.

6.3 P3: narzut długości

PK wydłuża tekst. Tabela 2 i rysunek 8 podają narzut w 6 miarach. W tokenach o200k mediana narzutu wynosi 37 %, a kwartyle wynoszą 13 % i 63 %. Przedział ufności 95 % dla mediany to od 23 % do 53 % włącznie. Średnia narzutu wynosi 49 %. Zdanie PK jest dłuższe niż zdanie zwykłe w 90 % przypadków. Wynik jest zgodny w 6 miarach: mediany leżą w przedziale od 36 % do 39 % włącznie.

Najwyższy narzut mają pozycje o terminach liczonych w dniach (reguła D4) oraz pozycja o mieszaniu spójników (reguła C2). Zdanie PK podaje tam dane, których zdanie zwykłe nie zawiera: dzień numer 1 albo strukturę listy. Narzut bliski 0 mają pozycje, w których PK zamienia 1 słowo, na przykład słowo „wszystkie” z przeczeniem na słowo „żaden”.

Pozycje typu konwencja nie zmieniają zdania. Kosztem jest legenda, którą autor podaje 1 raz w tekście; legendy zbioru mają co najwyżej 37 tokenów.

6.4 P4: sonda strefy szarej

Pomiar objął 5 modeli: 3 modele toru lokalnego i 2 modele toru Claude. Modele lokalne mają od 1,6 do 3,9 mld parametrów włącznie; modele Bielik opisuje raport techniczny [36]. Sprawozdanie z pomiarów podaje listę biegów. Tabela 3 podaje wynik każdego modelu, a rysunek 9 pokazuje odpowiedzi dla każdej pozycji.

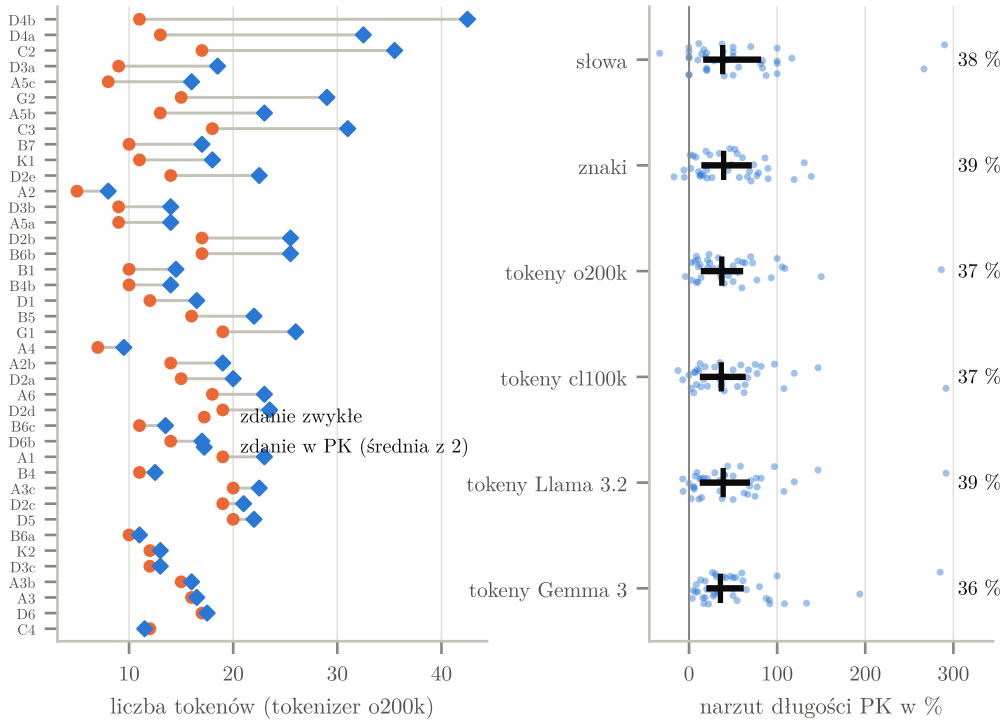
Kontrola kotwic. Trafność kotwic modeli lokalnych wynosi od 65 % do 90 % włącznie. Kontroli nie przeszło 1 z 3 modeli lokalnych. Model, który myli się w kotwicach, odpowiada błędnie także

Tabela 2: P3: narzut długości PK w procentach długości zdania zwykłego; 40 pozycji. Kolumna końcowa: udział zdań PK dłuższych niż zdanie zwykłe.

Miara	mediana	kwartyl 1	kwartyl 3	minimum	maksimum	dłuższe (%)
słowa	38	15	83	−33	290	78
znaki	39	13	73	−17	400	85
o200k	37	13	63	−4	286	90
cl100k	37	12	66	−12	292	85
Llama 3.2 3B	39	12	70	−7	292	85
Gemma 3 4B	36	19	64	4	285	94

PK wydłuża 90 % zdań; mediana narzutu wynosi 37 % tokenów (kwartyle: 13 % i 63 %)

Lewy panel: długość każdej pozycji. Prawy panel: narzut w 6 miarach; kreska: mediana, odcinek: kwartyle, liczba: mediana



Źródło: results/p3_tokens.json; n = 40 pozycji przeredagowanych, każda z 2 zdaniami PK.

Rysunek 8: Lingwistyka korpusowa: długość zdania zwykłego i zdania PK oraz rozkład narzutu w 6 miarach.

tam, gdzie zdanie ma 1 odczytanie. Wynik takiego modelu w strefie szarej nie mówi więc nic o PK. Praca podaje ten wynik w tabeli i pomija wynik takiego modelu w miarach zgodności.

Teza B: efekt rejestru. Zdania PK sterują odczytaniem modeli toru Claude. Trafność PK wynosi w tym torze od 91 % do 99 % włącznie, a sterowalność od 0,84 do 0,97 włącznie. Modele toru lokalnego mają trafność PK od 54 % do 74 % włącznie i sterowalność od 0,12 do 0,48 włącznie. Teza B zachodzi więc dla modeli toru Claude. Efekt rejestru jest w modelach lokalnych słabszy niż w modelach toru Claude.

Tabela 3: P4: wynik sondy. L: tor lokalny, C: tor Claude. n: liczba pozycji typu przeredagowanie. H: mediana niepewności w bitach. Znaki: liczba pozycji z niepewnością wyższą dla zdania zwykłego i liczba pozycji z niepewnością wyższą dla zdań PK; p: test znaków. Sterowalność: średnia. Kotwice: trafność w procentach; próg kontroli wynosi 80 %.

		H (bity)		test znaków			trafność	kotwice (%)	
Model	n	zwykłe	PK	znaki	p	sterow.	PK (%)	zwykłe	PK
C: haiku	38	–	–	–	–	0,84	91	–	–
C: sonnet	38	–	–	–	–	0,97	99	–	–
L: gemma3:4b	38	0,00	0,00	17:21	0,627	0,48	74	89	86
L: llama3.2:3b	38	0,06	0,06	20:18	0,871	0,12	54	67	65
L: bielik-1.5b-v3.0-instruct	38	0,91	0,89	24:14	0,143	0,19	70	90	86

Tabela 4: P4: pozycje typu konwencja (4 pozycje, reguły B2 i C1). Trafność w procentach i średnia sterowalność bez legendy oraz z legendą.

Model	trafność bez legendy	trafność z legendą	sterowalność bez legendy	sterowalność z legendą
C: haiku	75	100	0,50	1,00
C: sonnet	62	100	0,25	1,00
L: gemma3:4b	50	50	0,11	0,00
L: llama3.2:3b	62	62	0,11	0,17
L: bielik-1.5b-v3.0-instruct	62	50	0,10	0,03

Niepewność H w torze lokalnym ma medianę od 0,00 do 0,91 bita włącznie dla zdań zwykłych. Dla zdań PK mediana wynosi od 0,00 do 0,89 bita włącznie. Test znaków wykazał niższą niepewność zdań PK w 0 z 3 modeli lokalnych. Pomiar nie potwierdza więc, że PK zmniejsza niepewność modeli lokalnych. W torze Claude 2 próby dały różne odpowiedzi dla 10 % zdań zwykłych i dla 1 % zdań PK.

Rozbieżność czytelników. Miarę liczą modele, które przeszły kontrolę kotwic, oraz modele toru Claude: razem 4 modeli. Modele te wybierają różne odczytania zdania zwykłego w 31 z 44 pozycji, czyli w 70 % pozycji. Zdanie zwykłe dzieli więc czytelników tak, jak przewiduje model: zbiór odczytań ma więcej niż 1 element i czytelnicy wybierają różne elementy. Oba zdania PK odczytuje zgodnie z kluczem każdy z tych modeli w 13 z 44 pozycji.

Para modeli toru Claude daje obraz ostrzejszy. Modele Haiku i Sonnet wybierają różne odczytania zdania zwykłego w 5 z 44 pozycji i to samo odczytanie w 30 pozycjach. W 9 pozycjach co najmniej 1 model dał 2 różne odpowiedzi w 2 próbach. Oba zdania PK odczytują zgodnie z kluczem oba modele w 34 z 44 pozycji.

Teza C: konwencja i legenda. Tabela 4 podaje wynik pozycji typu konwencja. Reguła B2 ustala, że pierwszy rzeczownik jest podmiotem. Bez legendy modele odczytują zgodnie z kluczem 12 z 16 zdań tej reguły, a z legendą 12 zdań. Reguła C1 rozdziela słowa „lub” i „albo”. Bez legendy modele odczytują zgodnie z kluczem 8 z 16 zdań tej reguły, a z legendą 12 zdań.

Wynik odróżnia 2 konwencje. Konwencja B2 potwierdza nawyk: szyk podmiot, orzeczenie, dopełnienie jest w polszczyźnie szykiem domyślnym. Konwencja C1 zmienia nawyk: zwykła polszczyzna nie rozdziela słów „lub” i „albo” konsekwentnie. Konwencja zgodna z nawykiem działa bez legendy. Konwencja niezgodna z nawykiem wymaga legendy. Legendy wymaga także zdanie, w którym wiedza o świecie podpowiada inny podmiot. Model Sonnet odczytał zdanie „Napięcie wyłącza zabezpieczenie.” wbrew szykowi, a z legendą zgodnie z szykiem. Wniosek opiera się na 4 pozycjach i jest opisem przypadków.

Luki standardu. Zdanie G1, „Operatorowi NIE WOLNO włączyć pompy P1 i pompy P2.”, spełnia numerowane reguły PK. Odczytanie 1, czyli zakaz dla każdej pompy, wybiera 1 z 4 modeli; pozostałe modele wybierają zakaz włączenia 2 pomp naraz. Zdanie G2, „Każdy operator obsługuje dokładnie 1 pompę.”, odczytuje jako zdanie o różnych pompach 4 z 4 modeli. Liczba modeli, które odczytują oba zdania PK zgodnie z kluczem, wynosi 2 dla luki G1 i 2 dla luki G2. Luka jest groźna dla autora. Jeżeli autor zdania G1 zamierzył zakaz dla każdej pompy, to każdy model, który wybrał odczytanie 2, odczytał zdanie wbrew zamiarowi. Wynik potwierdza uwagę 3.1: zgodność z regułami numerowanymi nie gwarantuje 1 odczytania.

Pozycja ze spornym kluczem. Pozycja K2 ma zdanie PK „Zawór Z1 jest zamknięty [założenie].” i pytanie, czy tekst stwierdza fakt. Klucz podaje odpowiedź „Tak”. Oba modele toru Claude odpowiedziały „Nie”. Odpowiedź modeli jest uzasadniona: znacznik źródła mówi, że zdanie jest założeniem. Praca zostawia pozycję w wyniku jako błąd modeli, więc trafność toru Claude jest zaniżona o 1 pozycję. Obserwacja pokazuje przy okazji, że znacznik z modułu F zmienia odczytanie zdania przez model.

6.5 Próg opłacalności

Rysunek 10 łączy pomiary P3 i P4 wzorem (1). Mediana narzutu wynosi $\delta = 0{,}37$. Dla czytelnika, który odczytuje każde zdanie PK poprawnie, próg wynosi 27 %. Modele po kontroli odczytują zdania PK błędnie w 17 % przypadków; próg wynosi wtedy 39 %. PK jest tańsza w modelu kosztu, gdy błąd odczytania zdania zwykłego przekracza próg.

Zdanie ze strefy szarej i z 2 równie prawdopodobnymi odczytaniami daje błąd 50 %. Zdanie poza strefą szarą takiego błędu nie daje, a kontekst rozstrzyga część niejednoznaczności. Błąd odczytania całego tekstu jest więc niższy niż 50 %. Praca tej wielkości nie mierzy. Wzór wskazuje, gdzie PK się opłaca: w zdaniach, od których zależy działanie, i w tekstach, które czytelnik czyta bez kontekstu.

6.6 P5: miejsca wyboru w aktach prawnych

Tabela 5 i rysunek 11 podają wynik sprawdzarki na korpusie. Akty prawne mają od 43 do 71 trafień na 1000 słów włącznie. Teksty pisane w PK mają od 0,0 do 3,5 trafień na 1000 słów włącznie. Korpus aktów liczy 219 801 słów.

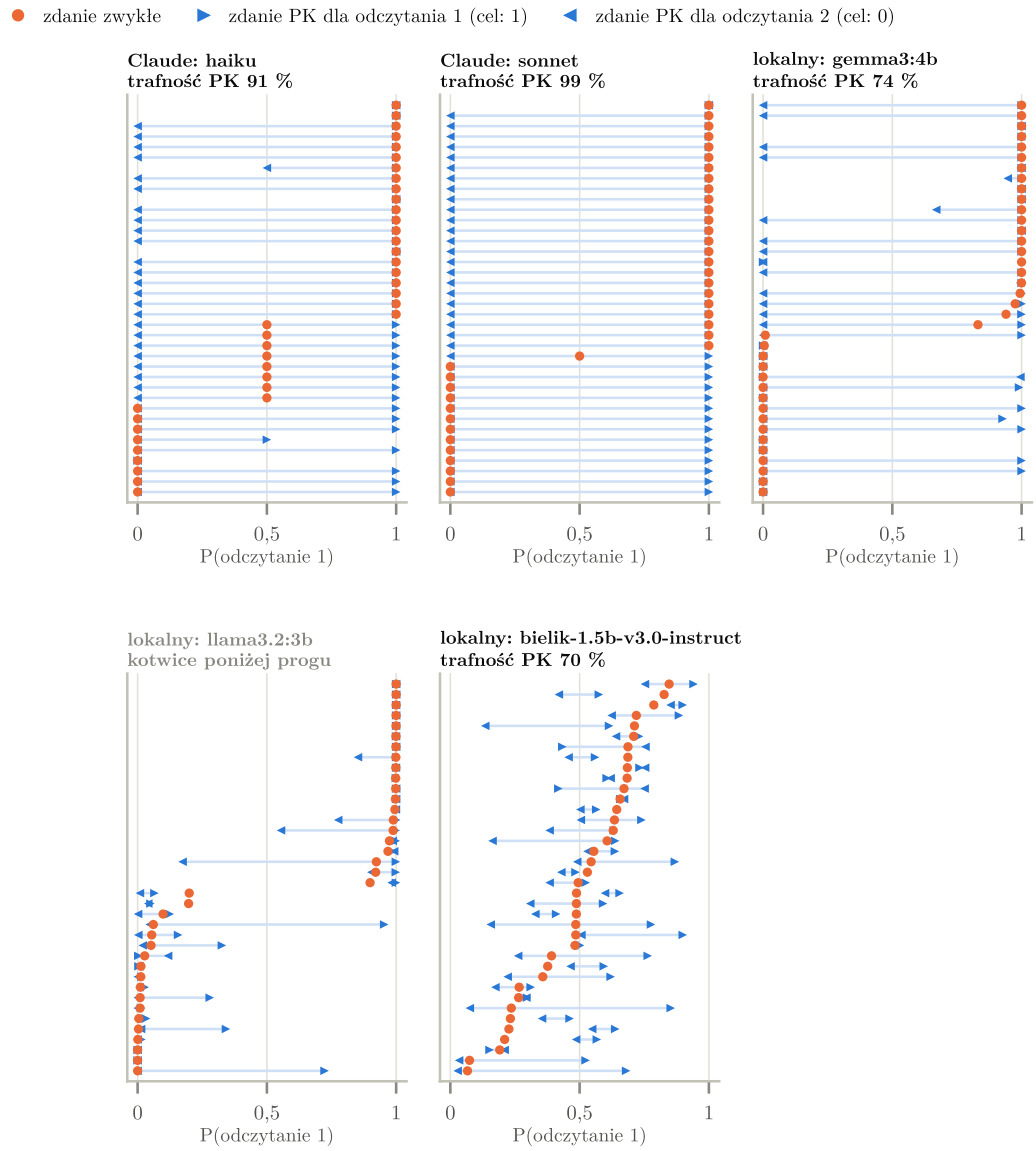
W aktach prawnych przeważają 4 kontrole. Kontrola A3 zgłasza zaimki. Kontrola KW zgłasza słowa „może” i „musi” poza zapisem słów kluczowych. Kontrola B8 zgłasza zdania dłuższe niż 25 słów. Kontrola A5 zgłasza słowa nieostre. Udział zdań dłuższych niż 25 słów wynosi w aktach od 12 % do 45 % włącznie. Podział aktu na zdania jest przybliżony, bo akt składa się z jednostek redakcyjnych, a nie ze zdań.

Ręczna ocena próby potwierdza trafność wskazań: 57 z 60 trafień wskazuje konstrukcję objętą regułą. Precyzja wynosi 95 %, a przedział Wilsona 95 % to od 86 % do 98 % włącznie. Czułości sprawdzarki praca nie mierzy.

Wynik wymaga 3 zastrzeżeń. Po pierwsze, trafienie wskazuje miejsce wyboru, a nie błąd aktu. Język prawny ma własne konwencje i własne procedury wykładni. Po drugie, nieostrość tekstu prawnego bywa celowa: słowo „niezwłocznie” zostawia sądowi ocenę przypadku (sekcja 7.6). Po trzecie, teksty pisane w PK także mają trafienia. Standard PK 0.1 zawiera 2 zdania z 2 przeczeniami, czyli narusza własną regułę C5. Część trafień w tekstach PK jest fałszywa: sprawdzarka zgłasza przymiotnik w nazwie „małe litery” jako słowo nieostre.

Zdania PK sterują odczytaniem modeli, które przeszły kontrolę: trafność od 70 % do 99 %; zdanie zwykłe dzieli te modele w 70 % pozycji

Każdy wiersz to 1 pozycja; pozycje uporządkowane według odpowiedzi modelu na zdanie zwykłe



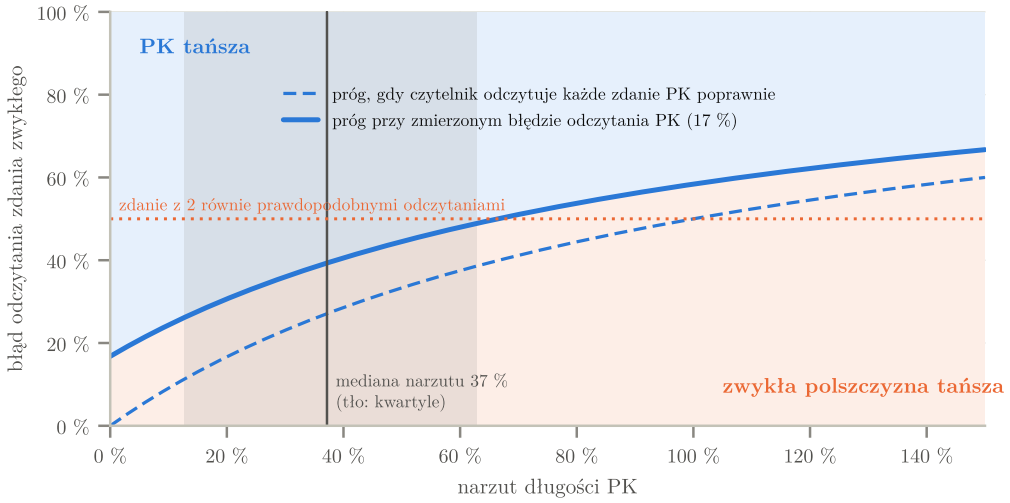
Źródło: results/p4_summary.json; n = 38 pozycji przeredagowanych na model, 5 modeli. Modele Claude: udział odpowiedzi „Tak” w 2 próbach.

Rysunek 9: Teoria informacji: prawdopodobieństwo odczytania 1 w strefie szarej dla zdania zwykłego i dla 2 zdań PK, osobno dla każdego modelu.

7 Refleksja filozoficzna w świetle hipotezy Sapira-Whorfa

7.1 Hipoteza i stan sporu

Humboldt pisał, że budowa języka wpływa na rozwój umysłowy ludzkości [20]. Sapir twierdził w roku 1929, że człowiek jest zdany na język społeczności, a obraz świata opiera się na nawykach językowych grupy [44]. Whorf sformułował w roku 1940 zasadę relatywizmu językowego: te same dane fizyczne prowadzą obserwatorów do tego samego obrazu świata tylko przy podobnym zapleczu



Rysunek 10: Model kosztu: próg opłacalności PK w funkcji narzutu długości.

Tabela 5: P5: wynik sprawdzarki na korpusie. Mediana: mediana długości zdania w słowach. Kolumna 4: udział zdań dłuższych niż 25 słów w procentach. Trafienia: trafienia 21 kontroli na 1000 słów. Kolumna końcowa: liczba wystąpień słowa „się” na 1000 słów; słowo „się” jest kandydatem do oceny, a nie naruszeniem.

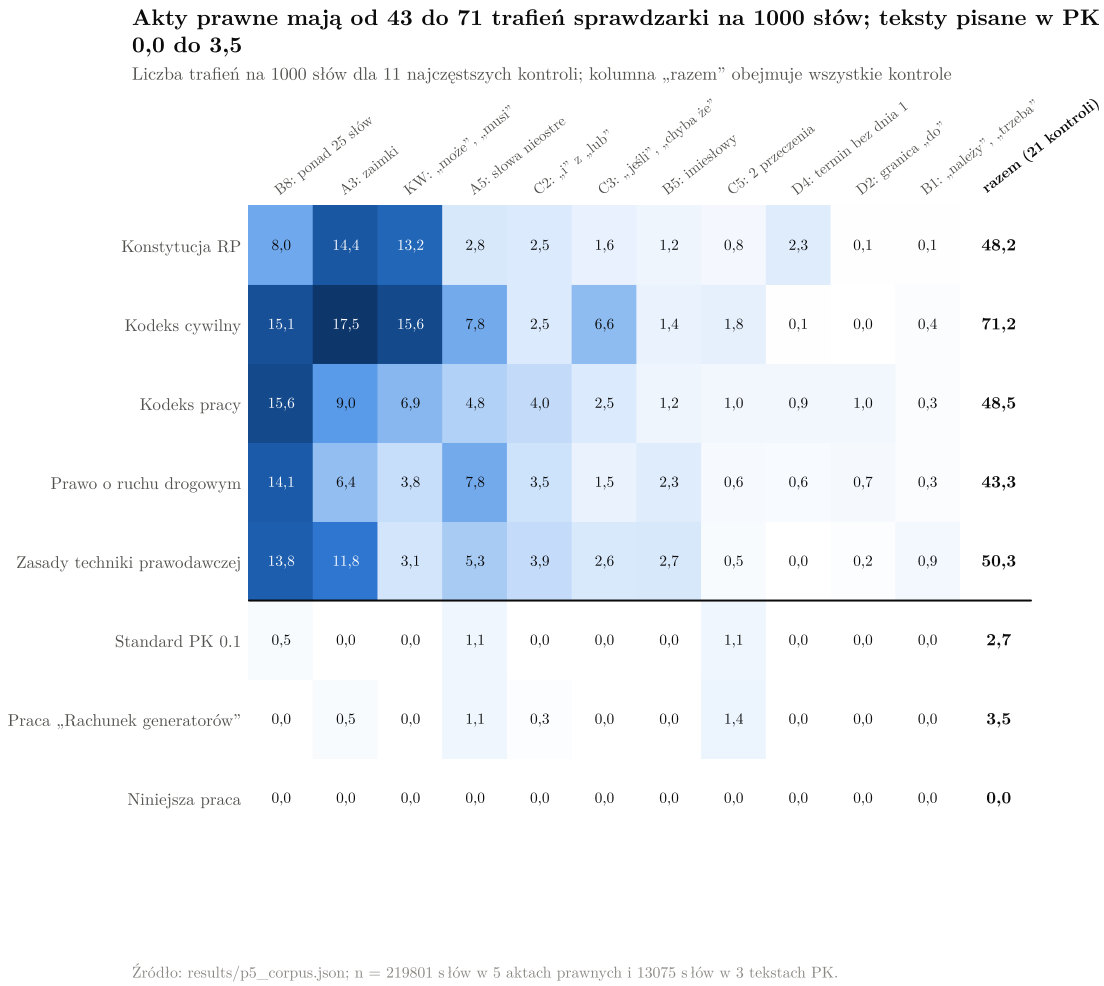
Tekst	słowa	mediana	ponad 25 (%)	trafienia	„się”
Konstytucja Rzeczypospolitej Polskiej	13 057	13	12	48,2	9,2
Kodeks cywilny	60 216	17	28	71,2	15,6
Kodeks pracy	49 374	18	35	48,5	8,7
Prawo o ruchu drogowym	83 125	23	45	43,3	8,7
Zasady techniki prawodawczej	14 029	16	29	50,3	36,3
Standard PK 0.1	1875	4	0	2,7	1,1
Praca „Rachunek generatorów”	3687	8	0	3,5	1,4
Niniejsza praca	7513	9	0	0,0	2,7

językowym [54, 55]. Nazwa „hipoteza Sapira-Whorfa” pochodzi od następców obu autorów.

Literatura rozróżnia 2 wersje hipotezy. Wersja mocna głosi, że język wyznacza myślenie. Wersja słaba głosi, że język wpływa na myślenie. Kay i Kempton wykryli wpływ nazw barw na ocenę podobieństwa barw [25]. Winawer i współautorzy pokazali, że osoby mówiące po rosyjsku szybciej rozróżniają 2 odcienie niebieskiego, gdy odcienie mają w języku rosyjskim różne nazwy [57]. Tom pod redakcją Gumperza i Levinsona porządkuje spór [19]. Wersja mocna nie ma potwierdzenia. Wersja słaba ma potwierdzenie w wybranych dziedzinach.

7.2 Tradycja polska

Polska filozofia ma własny wariant tezy. Ajdukiewicz ogłosił w roku 1934 radykalny konwencjonalizm: obraz świata zależy od aparatury pojęciowej, czyli od wyboru języka [2]. Schaff poświęcił hipotezie Sapira-Whorfa monografię „Język a poznanie” [46]. Bartmiński rozwinął pojęcie językowego obrazu świata [4]. Wierzbicka szuka pojęć prostych, które są wspólne językom [56].



Rysunek 11: Lingwistyka korpusowa: liczba trafień sprawdzarki na 1000 słów w aktach prawnych i w tekstach pisanych w PK.

Szkoła lwowsko-warszawska wiązała jasność języka z jasnością myślenia. Twardowski twierdził, że niejasny styl ma źródło w niejasnym myśleniu autora [51]. Tarski wykazał, że ścisła definicja prawdy wymaga języka o określonej strukturze [50]. PK korzysta z obu myśli. Reguły PK działają w kierunku przeciwnym do diagnozy Twardowskiego: wymóg jasnego zapisu wymusza jasną decyzję. Wynik Tarskiego wyznacza granicę: PK 0.1 nie ma struktury formalnej, a język PK_0 ma.

7.3 Ideał jednego znaczenia

PK należy do tradycji języka idealnego. Leibniz szukał alfabetu myśli, w którym spór zamienia się w rachunek [29]. Frege zbudował pismo pojęciowe i porównał stosunek tego pisma do języka potocznego ze stosunkiem mikroskopu do oka [16]. Wittgenstein pisze w „Traktacie logiczno-filozoficznym", że język potoczny przesłania formę myśli (teza 4.002) i że każdą myśl da się wypowiedzieć jasno (teza 4.116) [58]. Teza 5.6 wiąże granice języka z granicami świata. Carnap dodał zasadę tolerancji: zadaniem logika jest dochodzenie do konwencji, a nie ustanawianie zakazów [9]. Quine opisał regimentację, czyli parafrazę zdań potocznych na notację kanoniczną [43]. Montague odrzucił istotną różnicę teoretyczną między językiem naturalnym a językiem formalnym [35]. Brown opisał w roku 1960 język logiczny Loglan [8]; Loglan jest nowym językiem, a PK jest podzbiorem polszczyzny.

PK realizuje ten ideał skromnie. PK nie zastępuje polszczyzny notacją. PK wybiera z polszczyzny zdania, które czytelnik odczytuje w 1 sposób, i dokłada konwencje. Zasada tolerancji Carnapa

opisuje status PK trafnie: PK jest konwencją, którą autor przyjmuje dla 1 rodzaju tekstu.

Tradycja ma także krytyków. Późny Wittgenstein twierdzi, że reguła nie wyznacza własnego zastosowania; zastosowanie ustala praktyka wspólnoty [59]. Reguła E6 standardu PK mówi to samo językiem inżyniera: konwencja działa tylko dla czytelnika, który zna konwencję. Grice umieścił wśród maksym sposobu 2 zalecenia: unikaj wieloznaczności oraz mów zwięźle [18]. PK rozstrzyga konflikt tych maksym na korzyść jednoznaczności; pomiar P3 podaje cenę. Piantadosi, Tily i Gibson pokazali, że niejednoznaczność oszczędza wysiłek, gdy kontekst rozstrzyga znaczenie [39]. PK jest więc uzasadniona tam, gdzie kontekstu brakuje albo gdzie błąd odczytania kosztuje więcej niż dłuższy tekst.

7.4 PK jako zestaw kategorii obowiązkowych

Jakobson, za Boasem, ujął różnicę między językami jednym zdaniem: „Languages differ essentially in what they must convey and not in what they may convey" [22]. Polszczyzna każe podać rodzaj rzeczownika i aspekt czasownika. Polszczyzna pozwala pominąć wykonawcę, ilość, granicę przedziału i źródło wiedzy.

PK zmienia listę kategorii obowiązkowych dla 1 rejestru. Autor tekstu w PK podaje 5 danych.

- Wykonawca działania (reguła B1).
- Ilość albo nazwa obiektu (reguła A2).
- Strona granicy przedziału (reguła D2).
- Chwila w kalendarzu (reguła D3).
- Źródło wiedzy (moduł F).

Moduł F jest odpowiednikiem ewidencjalności. Aikhenvald opisała języki, w których każde zdanie wskazuje źródło informacji: mówiący widział zdarzenie, słyszał o zdarzeniu albo wnioskuje [1]. PK wprowadza tę kategorię do polszczyzny konwencją, a nie gramatyką.

Slobin nazwał wpływ kategorii obowiązkowych „myśleniem dla mówienia": mówiący kieruje uwagę na cechy, które gramatyka każe wyrazić [48]. Praca stawia analogiczną hipotezę dla pisania. Autor, który pisze w PK, rozstrzyga fakty, które zwykła polszczyzna pozwala zostawić bez rozstrzygnięcia. Gdy autor faktu nie zna, standard każe wstawić znacznik „[DO USTALENIA]". Przykład ze standardu pokazuje skalę zjawiska: 3 zdania instrukcji dają 3 znaczniki braku. PK ujawnia więc niewiedzę autora przed wykonaniem instrukcji. Hipoteza jest słabą wersją tezy Sapira-Whorfa dla 1 rejestru. Praca tej hipotezy nie testuje; test wymaga badania z udziałem ludzi.

7.5 Hipoteza Sapira-Whorfa a model językowy

Model językowy jest funkcją: ciąg tokenów wyznacza rozkład prawdopodobieństwa kolejnego tokenu. Praca rozdziela pytanie o hipotezę Sapira-Whorfa dla modelu na 3 tezy o różnym statusie.

Teza A: zależność od tekstu. Zadanie dociera do modelu wyłącznie jako tekst. Odpowiedź modelu zależy więc od sformułowania zadania. Teza A zachodzi z samej budowy modelu i nie wymaga pomiaru. Dla człowieka mocna wersja hipotezy jest sporna, bo człowiek poznaje świat także poza językiem. Model językowy takiej drogi nie ma: granice tekstu wejściowego są granicami zadania. Bender i Koller ostrzegają przed wnioskiem, że system wyuczony na samej formie języka ma dostęp do znaczenia [6]. Praca stosuje tę ostrożność: słowo „odczytanie" oznacza w pomiarze P4 rozkład odpowiedzi modelu, a nie stan umysłu.

Teza B: efekt rejestru. Ta sama treść zapisana w PK i w zwykłej polszczyźnie daje różne rozkłady odpowiedzi. Teza B jest empiryczna; wynik podaje sekcja 6.4.

Teza C: efekt nawyku. Model uczy się na tekstach w zwykłej polszczyźnie, więc nie zna konwencji PK. Konwencja działa na model dopiero wtedy, gdy tekst zawiera legendę. Teza C przenosi regułę E6 na model językowy; wynik podaje sekcja 6.4.

Literatura dostarcza 2 obserwacji o języku wejścia. Wendler i współautorzy pokazali, że w modelach rodziny Llama-2 reprezentacje warstw pośrednich leżą bliżej języka angielskiego niż języka zapytania [53]. Kim i współautorzy zmierzyli 26 języków w zadaniach wyszukiwania w tekście o długości 64 tys. i 128 tys. tokenów [26]. Język polski zajął miejsce 1, a język angielski miejsce 6. Wynik dotyczy 7 zadań tego testu i nie dowodzi ogólnej przewagi polszczyzny. Oba wyniki mówią o języku naturalnym jako całości. Niniejsza praca bada węższe pytanie: rejestr wewnątrz 1 języka.

Hipoteza ma więc dla modelu inny kształt niż dla człowieka. U człowieka spór dotyczy trwałego wpływu języka ojczystego na poznanie. U modelu wpływ tekstu wejściowego jest doraźny i całkowity, a ciekawe pytanie brzmi: które cechy tekstu zmieniają rozkład odpowiedzi.

7.6 Granice

Nowomowa. Orwell opisał język zaprojektowany po to, żeby zawęzić zakres myśli [38]. Model z sekcji 3 pokazuje różnicę między nowomową a PK. Nowomowa zmniejsza zbiór znaczeń, które użytkownik potrafi wyrazić, czyli obraz relacji interpretacji w zbiorze M. PK zmniejsza zbiory odczytań pojedynczych zdań. Dla każdego ostrego odczytania zdania zwykłego standard PK wskazuje osobne zdanie PK; tabela w dodatku B zawiera 88 takich zdań. Nowomowa odbiera rozróżnienia, a PK wymusza rozróżnienia. PK jest także dobrowolna i obejmuje 1 rejestr.

Nieostrość celowa. PK usuwa znaczenia nieostre, a nieostrość bywa potrzebna. Ustawodawca pisze „niezwłocznie” albo „należyta staranność”, żeby zostawić sądowi ocenę przypadku. Pomiar P5 pokazuje, że akty prawne używają takich słów stale. Standard PK zastrzega, że umowa w PK nadal wymaga oceny prawnika. PK nie nadaje się także do literatury, reklamy i rozmowy; standard wyłącza te rodzaje tekstu.

Konwencja wymaga wspólnoty. Jednoznaczność zdania PK nie jest własnością samego ciągu słów. Zdanie „Ciśnienie zmienia przepływ.” jest tym samym ciągiem słów w PK i poza PK. Jednoznaczność powstaje dopiero dla czytelnika, który zna regułę B2. PK jest więc umową między autorem a czytelnikiem. Rysunek 12 umieszcza PK na tle 3 tradycji, z których standard korzysta.

8 Zagrożenia dla trafności

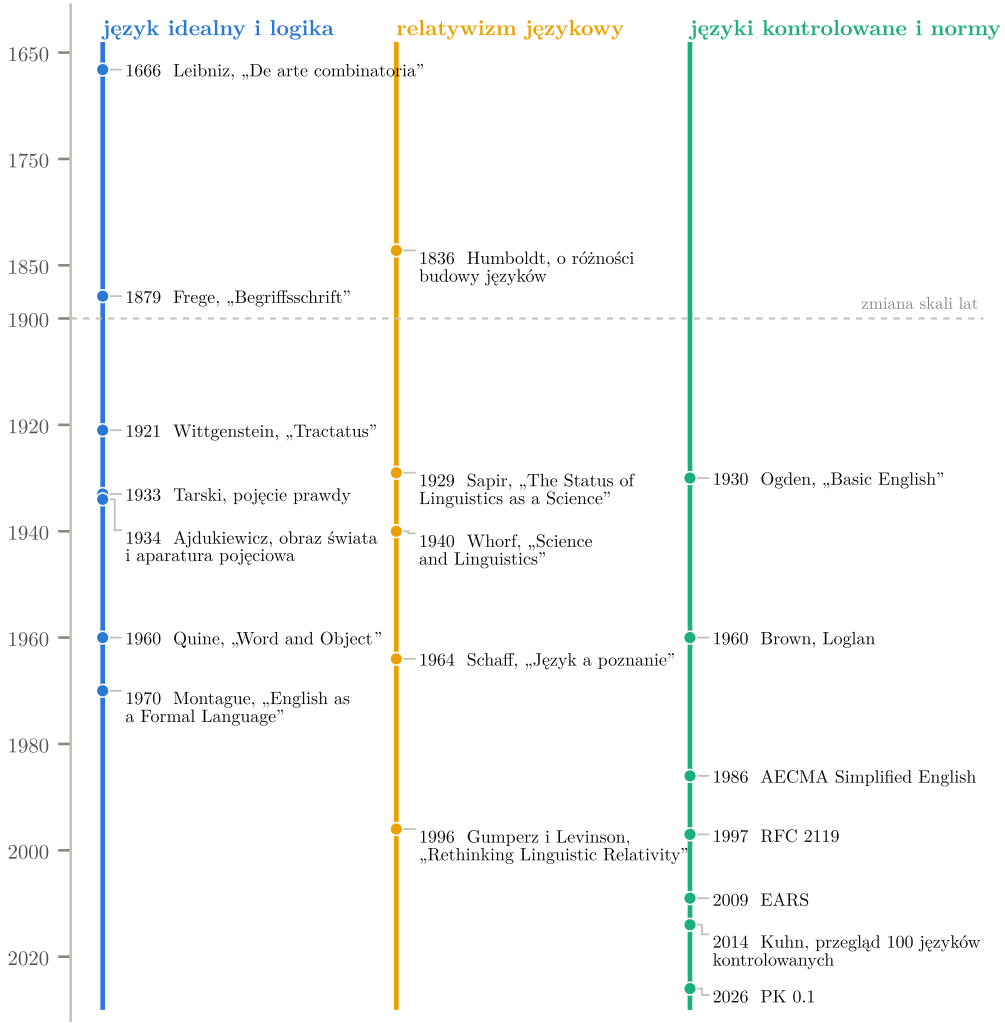
Trafność konstrukcji. Sonda wymusza odpowiedź „Tak” albo „Nie”. Model nie ma opcji „zdanie jest niejednoznaczne”. Pytanie sondy wskazuje strefę szarą, więc sonda mierzy wybór odczytania, a nie wykrycie niejednoznaczności. Zdania pomiaru stoją bez kontekstu. W tekście kontekst rozstrzyga część niejednoznaczności, więc pomiar zawyża skalę problemu zdań zwykłych.

Trafność wewnętrzna. Ten sam autor napisał standard, pozycje testowe, klucz odpowiedzi i sprawdzarkę. Autor napisał 28 z 44 pozycji po zaprojektowaniu pomiaru. Klasyfikację reguł i ocenę precyzji wykonał 1 oceniający. Praca nie ma oceny językoznawcy. Autor ustalił próg kontroli kotwic, czyli 80 %, po obejrzeniu wyniku pierwszego modelu. Pozycja K2 ma sporny klucz (sekcja 6.4).

Trafność zewnętrzna. Modele lokalne mają od 1,6 do 3,9 mld parametrów włącznie; tor Claude obejmuje 2 modele. Wynik nie przenosi się wprost na inne modele. Pozycje opisują instalacje,

PK łączy 3 tradycje: logiczny ideał jednego znaczenia, tezę o wpływie języka na myślenie i inżynierskie języki kontrolowane

Oś czasu wybranych prac; czas biegnie w dół



Źródło: bibliografia pracy; n = 19 pozycji.

Rysunek 12: Historia idei: wybrane prace 3 tradycji, które łączy PK.

terminy i regulaminy; inne dziedziny wymagają osobnego pomiaru. Praca nie zawiera badania z udziałem ludzi.

Wnioskowanie statystyczne. Pomiar P4 ma 38 pozycji typu przeredagowanie, 4 pozycje typu konwencja i 2 pozycje typu luka. Wynik dla konwencji i dla luk jest opisem przypadków, a nie estymacją. Test znaków nie ma poprawki na liczbę modeli. Tor Claude ma 2 próby na sondę.

Model formalny. Twierdzenie 3.1 zakłada niezależne miejsca wyboru. Twierdzenie 4.1 wymaga rozkładu zamierzonych odczytań, którego praca nie zna. Twierdzenia 4.2 i 4.3 dotyczą języka PK_0, a nie pełnej PK 0.1. Gramatyki pomiaru P2 modelują 1 konstrukcję. Twierdzenie 4.4 zakłada niezależne próby; model językowy z temperaturą 0 powtarza ten sam błąd, więc wzór opisuje zbiór zadań, a nie powtórzenia 1 zadania.

Sprawdzarka. Sprawdzarka jest przybliżona. Precyzja pochodzi z próby 60 trafień; czułość jest nieznana. Sprawdzarka nie obejmuje reguł, które wymagają składni albo znaczenia.

9 Wnioski

Praca odpowiada na 4 pytania z wprowadzenia.

Pytanie (i): model. Język jest parą: zbiór zdań i relacja interpretacji. Reguła PK jest ograniczeniem albo konwencją; obie operacje są przecięciem z ustalonym zbiorem, więc reguły są przemienne. PK dąży do tego, żeby relacja interpretacji była funkcją. Numerowane reguły PK 0.1 tego celu nie gwarantują: praca wskazuje 2 zdania zgodne z regułami, które mają 2 odczytania.

Pytanie (ii): koszty. Teza z tytułu zachodzi w 3 znaczeniach i nie zachodzi w 1 znaczeniu.

- PK zmniejsza zbiór odczytań. Zdanie z 8 frazami przyimkowymi ma 4862 odczytania; zdanie PK ma 1 odczytanie. Brak informacji w zdaniu PK wynosi 0 bitów.
- PK zmniejsza koszt parsowania w modelu gramatyki: zmierzony wykładnik spada z 2,53 do 1,77.
- PK wyznacza granicę kosztu wnioskowania. Zbiór wymagań bez przeczeń ma kontrolę spójności w czasie liniowym. Zbiór wymagań z 1 przeczeniem w zdaniu ma kontrolę spójności NP-zupełną.
- PK nie zmniejsza kosztu przejścia tekstu przez model językowy. Tekst PK jest dłuższy: mediana narzutu wynosi 37 % tokenów.

Pytanie (iii): pomiar. Modele toru Claude odczytują zdania PK zgodnie z kluczem w co najmniej 91 % przypadków. Modele lokalne osiągają od 54 % do 74 % włącznie przy poziomie przypadku 50 %. Zdanie zwykłe dzieli modele po kontroli w 70 % pozycji. Korzyść z PK zależy więc od czytelnika: PK pomaga modelowi, który czyta polskie zdanie poprawnie, i nie zastępuje tej zdolności. Próg opłacalności w modelu kosztu wynosi 39 % błędnych odczytań zdania zwykłego.

Pytanie (iv): hipoteza Sapira-Whorfa. PK zmienia listę kategorii, które autor wyraża obowiązkowo: wykonawca, ilość, granica, chwila, źródło wiedzy. Dla człowieka praca stawia hipotezę: pisanie w PK ujawnia autorowi braki w wiedzy o opisywanej czynności. Dla modelu językowego praca rozdziela hipotezę na 3 tezy. Zależność odpowiedzi od tekstu zachodzi z budowy modelu. Efekt rejestru zachodzi dla modeli toru Claude. Efekt nawyku widać w pozycjach typu konwencja: konwencja niezgodna z nawykiem działa dopiero z legendą.

Zalecenia dla standardu. Wyniki dają 4 zalecenia dla kolejnej wersji PK.

1. Dodać regułę o zasięgu zakazu nad spójnikiem „i” (luka G1).
2. Dodać regułę o zasięgu 2 kwantyfikatorów w 1 zdaniu (luka G2).
3. Poprawić 2 zdania standardu, które mają 2 przeczenia.
4. Zalecić legendę przy każdym tekście dla modelu językowego, który zawiera słowo „lub” albo słowo „albo”.

Dalsze prace. Praca zostawia 5 zadań.

- Gramatyka formalna dla rdzenia PK.

- Sprawdzarka z analizą składni.
- Pomiar na modelach o większej liczbie parametrów.
- Pomiar na tekstach z kontekstem.
- Badanie z udziałem ludzi, które sprawdzi hipotezę o ujawnianiu braków wiedzy.

Literatura

[1] A. Y. Aikhenvald. *Evidentiality*. Oxford University Press, Oxford 2004.

[2] K. Ajdukiewicz. Das Weltbild und die Begriffsapparatur. *Erkenntnis* 4 (1934), 259–287.

[3] ASD. *ASD-STE100 Simplified Technical English*, Issue 9. AeroSpace, Security and Defence Industries Association of Europe, Bruksela 2025. https://www.asd-ste100.org

[4] J. Bartmiński. *Językowe podstawy obrazu świata*. Wydawnictwo UMCS, Lublin 2006.

[5] G. E. Barton. On the complexity of ID/LP parsing. *Computational Linguistics* 11(4) (1985), 205–218.

[6] E. M. Bender, A. Koller. Climbing towards NLU: on meaning, form, and understanding in the age of data. *Proceedings of the 58th Annual Meeting of the ACL* (2020), 5185–5198.

[7] S. Bradner. *Key words for use in RFCs to indicate requirement levels*. RFC 2119, 1997. https://doi.org/10.17487/RFC2119

[8] J. C. Brown. Loglan. *Scientific American* 202(6) (1960), 53–63.

[9] R. Carnap. *Logische Syntax der Sprache*. Springer, Wiedeń 1934.

[10] K. Church, R. Patil. Coping with syntactic ambiguity or how to put the block in the box on the table. *American Journal of Computational Linguistics* 8(3–4) (1982), 139–149.

[11] S. A. Cook. The complexity of theorem-proving procedures. *Proceedings of the 3rd Annual ACM Symposium on Theory of Computing* (1971), 151–158.

[12] W. F. Dowling, J. H. Gallier. Linear-time algorithms for testing the satisfiability of propositional Horn formulae. *Journal of Logic Programming* 1(3) (1984), 267–284.

[13] J. Earley. An efficient context-free parsing algorithm. *Communications of the ACM* 13(2) (1970), 94–102.

[14] S. Farquhar, J. Kossen, L. Kuhn, Y. Gal. Detecting hallucinations in large language models using semantic entropy. *Nature* 630 (2024), 625–630.

[15] K. Fine. Vagueness, truth and logic. *Synthese* 30(3–4) (1975), 265–300.

[16] G. Frege. *Begriffsschrift, eine der arithmetischen nachgebildete Formelsprache des reinen Denkens*. Louis Nebert, Halle 1879.

[17] N. E. Fuchs, K. Kaljurand, T. Kuhn. Attempto Controlled English for knowledge representation. *Reasoning Web 2008*, Lecture Notes in Computer Science 5224, Springer (2008), 104–124.

[18] H. P. Grice. Logic and conversation. W: P. Cole, J. Morgan (red.), *Syntax and Semantics 3: Speech Acts*. Academic Press, Nowy Jork 1975, 41–58.

[19] J. J. Gumperz, S. C. Levinson (red.). *Rethinking Linguistic Relativity*. Cambridge University Press, Cambridge 1996.

[20] W. von Humboldt. *Über die Verschiedenheit des menschlichen Sprachbaues und ihren Einfluss auf die geistige Entwickelung des Menschengeschlechts*. F. Dümmler, Berlin 1836.

[21] ISO. *ISO 24495-1:2023 Plain language. Part 1: Governing principles and guidelines*. Genewa 2023.

[22] R. Jakobson. On linguistic aspects of translation. W: R. A. Brower (red.), *On Translation*. Harvard University Press, Cambridge 1959, 232–239.

[23] D. Kaplan. Demonstratives. W: J. Almog, J. Perry, H. Wettstein (red.), *Themes from Kaplan*. Oxford University Press, Nowy Jork 1989, 481–563.

[24] P. Kapłański. Controlled English interface for knowledge bases. *Studia Informatica* 32(2A) (2011), 485–494.

[25] P. Kay, W. Kempton. What is the Sapir-Whorf hypothesis? *American Anthropologist* 86(1) (1984), 65–79.

[26] Y. Kim, J. Russell, M. Karpinska, M. Iyyer. *One ruler to measure them all: benchmarking multilingual long-context language models*. arXiv:2503.01996, 2025.

[27] D. E. Knuth. On the translation of languages from left to right. *Information and Control* 8(6) (1965), 607–639.

[28] T. Kuhn. A survey and classification of controlled natural languages. *Computational Linguistics* 40(1) (2014), 121–170.

[29] G. W. Leibniz. *Dissertatio de arte combinatoria*. Lipsk 1666.

[30] J. M. I. M. Leo. A general context-free parsing algorithm running in linear time on every LR(k) grammar without using lookahead. *Theoretical Computer Science* 82(1) (1991), 165–176.

[31] A. Liu, Z. Wu, J. Michael, A. Suhr, P. West, A. Koller, S. Swayamdipta, N. A. Smith, Y. Choi. We're afraid language models aren't modeling ambiguity. *Proceedings of EMNLP 2023*, 790–807.

[32] A. Mavin, P. Wilkinson, A. Harwood, M. Novak. Easy Approach to Requirements Syntax (EARS). *Proceedings of the 17th IEEE International Requirements Engineering Conference* (2009), 317–322.

[33] W. Merrill, A. Sabharwal. The parallelism tradeoff: limitations of log-precision transformers. *Transactions of the ACL* 11 (2023), 531–545.

[34] S. Min, J. Michael, H. Hajishirzi, L. Zettlemoyer. AmbigQA: answering ambiguous open-domain questions. *Proceedings of EMNLP 2020*, 5783–5797.

[35] R. Montague. English as a formal language. W: B. Visentini i in. (red.), *Linguaggi nella società e nella tecnica*. Edizioni di Comunità, Mediolan 1970, 189–224.

[36] K. Ociepa, Ł. Flis, R. Kinas, K. Wróbel, A. Gwoździej. *Bielik v3 Small: technical report*. arXiv:2505.02550, 2025.

[37] C. K. Ogden. *Basic English: A General Introduction with Rules and Grammar*. Kegan Paul, Trench, Trubner, Londyn 1930.

[38] G. Orwell. *Nineteen Eighty-Four*. Secker & Warburg, Londyn 1949. Dodatek: The principles of Newspeak.

[39] S. T. Piantadosi, H. Tily, E. Gibson. The communicative function of ambiguity in language. *Cognition* 122(3) (2012), 280–291.

[40] I. Pratt-Hartmann. Fragments of language. *Journal of Logic, Language and Information* 13(2) (2004), 207–223.

[41] I. Pratt-Hartmann, A. Third. More fragments of language. *Notre Dame Journal of Formal Logic* 47(2) (2006), 151–177.

[42] S. Przybyszewski. O użyciu operatorów kwantyfikacji ogólnej w zdaniach przeczących. *Język Polski* 2020, z. 3, 5–19.

[43] W. V. O. Quine. *Word and Object*. MIT Press, Cambridge 1960.

[44] E. Sapir. The status of linguistics as a science. *Language* 5(4) (1929), 207–214.

[45] T. J. Schaefer. The complexity of satisfiability problems. *Proceedings of the 10th Annual ACM Symposium on Theory of Computing* (1978), 216–226.

[46] A. Schaff. *Język a poznanie*. Państwowe Wydawnictwo Naukowe, Warszawa 1964.

[47] C. E. Shannon. A mathematical theory of communication. *Bell System Technical Journal* 27 (1948), 379–423, 623–656.

[48] D. I. Slobin. From *thought and language* to *thinking for speaking*. W: [19], 70–96.

[49] M. Szulia. *Polszczyzna Kontrolowana (PK) 0.1*. 2026, wersja `15503a4`. https://github.com/maciejszulia/polszczyzna-kontrolowana

[50] A. Tarski. *Pojęcie prawdy w językach nauk dedukcyjnych*. Prace Towarzystwa Naukowego Warszawskiego, Wydział III, nr 34, Warszawa 1933.

[51] K. Twardowski. O jasnym i niejasnym stylu filozoficznym. *Ruch Filozoficzny* 5 (1919).

[52] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, I. Polosukhin. Attention is all you need. *Advances in Neural Information Processing Systems* 30 (2017), 5998–6008.

[53] C. Wendler, V. Veselovsky, G. Monea, R. West. Do llamas work in English? On the latent language of multilingual transformers. *Proceedings of the 62nd Annual Meeting of the ACL* (2024), 15366–15394.

[54] B. L. Whorf. Science and linguistics. *Technology Review* 42(6) (1940), 229–231, 247–248.

[55] B. L. Whorf. *Language, Thought, and Reality: Selected Writings*. Red. J. B. Carroll. MIT Press, Cambridge 1956.

[56] A. Wierzbicka. *Semantics: Primes and Universals*. Oxford University Press, Oxford 1996.

[57] J. Winawer, N. Witthoft, M. C. Frank, L. Wu, A. R. Wade, L. Boroditsky. Russian blues reveal effects of language on color discrimination. *Proceedings of the National Academy of Sciences* 104(19) (2007), 7780–7785.

[58] L. Wittgenstein. Logisch-philosophische Abhandlung. *Annalen der Naturphilosophie* 14 (1921). Wydanie polskie: *Tractatus logico-philosophicus*, przeł. B. Wolniewicz. Państwowe Wydawnictwo Naukowe, Warszawa 1970.

[59] L. Wittgenstein. *Philosophical Investigations*. Przeł. G. E. M. Anscombe. Basil Blackwell, Oksford 1953.

[60] *Zasady techniki prawodawczej*. Tekst jednolity: Dz.U. 2026 poz. 300.

[61] Z. Ziembiński. *Logika praktyczna*. Wyd. 25. Wydawnictwo Naukowe PWN, Warszawa 2002.

A Legenda konwencji PK użytych w pracy

- „Lub” znaczy co najmniej 1 z członów. „Albo” znaczy dokładnie 1 z członów.
- „Co najmniej N” znaczy $x \geq N$. „Co najwyżej N” znaczy $x \leq N$. „Od A do B włącznie” znaczy $A \leq x \leq B$.
- Pierwszy rzeczownik w zdaniu jest podmiotem.
- Słowo „tylko” stoi bezpośrednio przed słowem ograniczanym.
- Znacznik w nawiasie kwadratowym, na przykład „[założenie]”, podaje źródło faktu.
- Słowa „MUSI”, „NIE WOLNO” i „MOŻE” pisane wielkimi literami są słowami kluczowymi wymagań.

B Pozycje testowe

Kolumna R podaje rodzaj pozycji: O oznacza przeredagowanie, K oznacza konwencję, L oznacza lukę. Kolumna Ź podaje źródło zdania: S oznacza standard PK 0.1, A oznacza autora. Zdania PK i sondy każdej pozycji zawiera plik `data/items.csv`.

Nr	Reguła	R	Ź	Zdanie zwykłe	Odczytanie 1; odczytanie 2
A1	A1	O	S	„Zamknij zawór. Sprawdź, czy kurek jest szczelny.”	kurek i zawór to 1 element; kurek to inny element niż zawór
A2	A2	O	S	„Wymień filtr.”	co najmniej 1 filtr; każdy filtr
A2b	A2	O	A	„Operator sprawdza zawór przed uruchomieniem pompy.”	każdy zawór; co najmniej 1 zawór
A3	A3	O	S	„Jan powiedział Piotrowi, że jego pompa przecieka.”	przecieka pompa Jana; przecieka pompa Piotra
A3b	A3	O	A	„Kierownik polecił operatorowi sprawdzić swoje stanowisko.”	stanowisko kierownika; stanowisko operatora
A3c	A3	O	A	„Zawór Z1 jest połączony z filtrem F1. Wymień go.”	polecenie dotyczy zaworu Z1; polecenie dotyczy filtra F1
A4	A4	O	A	„Wyślij ostatni raport.”	raport najnowszy; raport końcowy
A5a	A5	O	S	„Regularnie sprawdzaj ciśnienie.”	odstęp 15 min; odstęp 7 dni
A5b	A5	O	A	„Zgłoś awarię niezwłocznie.”	czas krótszy niż 15 min; czas krótszy niż 24 h
A5c	A5	O	A	„Dodaj kilka kropli oleju.”	od 2 do 5 kropli; od 3 do 9 kropli
A6	A6	O	A	„Gościom nie wolno wnosić noży, nożyczek itp.”	zakaz obejmuje tylko noże i nożyczki; zakaz obejmuje także inne ostre narzędzia
B1	B1	O	S	„Zawór zamyka się po pracy.”	urządzenie zamyka zawór; człowiek zamyka zawór
B2	B2	K	S	„Ciśnienie zmienia przepływ.”	ciśnienie działa na przepływ; przepływ działa na ciśnienie
B2b	B2	K	A	„Napięcie wyłącza zabezpieczenie.”	napięcie działa na zabezpieczenie; zabezpieczenie działa na napięcie
B4	B4	O	S	„Kontrola pracownika trwała 2 godziny.”	pracownik kontrolował; pracownik był kontrolowany
B4b	B4	O	A	„Ocena dostawcy trwa 5 dni.”	dostawca ocenia; dostawca jest oceniany
B5	B5	O	A	„Kierownik zauważył operatora, wychodząc z hali.”	z hali wychodził kierownik; z hali wychodził operator
B6a	B6	O	S	„Wymień stare kable i przewody.”	stare kable i każdy przewód; stare kable i stare przewody
B6b	B6	O	S	„Kierownik powiadomił operatora o awarii w biurze.”	awaria wystąpiła w biurze; powiadomienie nastąpiło w biurze
B6c	B6	O	A	„Sprawdź 3 zawory i pompy.”	3 zawory i każda pompa; 3 zawory i 3 pompy
B7	B7	O	A	„Technik tylko wymienił filtr F1.”	technik nie wykonał innej czynności przy filtrze F1; technik nie wymienił innej części
C1	C1	K	S	„Zapłać kartą lub gotówką.”	co najmniej 1 forma płatności; dokładnie 1 forma płatności
C1b	C1	K	A	„Jeżeli czujnik C1 lub czujnik C2 zgłasza alarm, to sterownik wyłącza pompę P1.”	co najmniej 1 czujnik; dokładnie 1 czujnik
C2	C2	O	S	„Włącz pompę P1 i pompę P2 lub pompę P3.”	(P1 i P2) lub P3; P1 i (P2 lub P3)
C3	C3	O	A	„Zamknij zawór Z1, chyba że pompa P1 pracuje.”	przy pracy pompy zamknięcie jest zabronione; przy pracy pompy tekst nie daje polecenia
C4	C4	O	S	„Wszystkie zawory nie są zamknięte.”	żaden zawór nie jest zamknięty; nie każdy zawór jest zamknięty
D1	D1	O	S	„Ciśnienie w instalacji: 2,5.”	2,5 bar; 2,5 MPa
D2a	D2	O	S	„Dzieci do 3 lat wchodzą bezpłatnie.”	wiek mniejszy niż 3 lata; wiek mniejszy niż 4 lata
D2b	D2	O	A	„Rabat dotyczy zamówień od 5 do 10 sztuk.”	10 sztuk włącznie; mniej niż 10 sztuk

Nr	Reguła	R	Ź	Zdanie zwykłe	Odczytanie 1; odczytanie 2
D2c	D2	O	A	„Dostawa jest bezpłatna dla zamówień powyżej 100 zł.”	wartość większa niż 100 zł; wartość co najmniej 100 zł
D2d	D2	O	A	„Urządzenie pracuje w temperaturze między 10 °C a 30 °C.”	granice włączone; granice wyłączone
D2e	D2	O	A	„W zawodach startują osoby w wieku 18–25 lat.”	wiek mniejszy niż 26 lat; wiek co najwyżej 25 lat
D3a	D3	O	S	„Wyślij raport do piątku.”	termin obejmuje piątek; termin kończy się przed piątkiem
D3b	D3	O	A	„Dostawa przyjedzie jutro.”	dzień po dniu napisania; dzień po dniu czytania
D3c	D3	O	A	„Spotkanie odbędzie się w następny piątek.”	najbliższy piątek; piątek w kolejnym tygodniu
D4a	D4	O	S	„Złóż reklamację w ciągu 14 dni.”	dzień 1 to dzień odbioru; dzień 1 to dzień po dniu odbioru
D4b	D4	O	A	„Odpowiemy w ciągu 3 dni.”	dni kalendarzowe; dni robocze
D5	D5	O	A	„Oprocentowanie kredytu wynosiło 4 % i wzrosło o 1 %.”	wzrost o 1 punkt procentowy, wynik 5 %; wzrost o 1 % wartości, wynik 4,04 %
D6	D6	O	A	„Fundusz zarządza aktywami o wartości 2 bilionów dolarów.”	$2 \times 10\hat{}12$ dolarów; $2 \times 10\hat{}9$ dolarów
D6b	D6	O	A	„Odległość między słupami wynosi około 50 m.”	tolerancja $\pm$ 5 m; tolerancja $\pm$ 10 m
K1	KW	O	A	„Pompa P1 może pracować bez wody.”	zezwolenie; możliwość zdarzenia
K2	KW	O	A	„Zawór Z1 musi być zamknięty.”	wymóg; wniosek o stanie faktycznym
G1	luka	L	A	„Operatorowi NIE WOLNO włączyć pompy P1 i pompy P2.”	zakaz dotyczy każdej z 2 pomp; zakaz dotyczy włączenia 2 pomp naraz
G2	luka	L	A	„Każdy operator obsługuje dokładnie 1 pompę.”	każdy operator ma 1 pompę, pompy różnych operatorów bywają różne; wszyscy operatorzy obsługują tę samą 1 pompę

C Powtarzalność

Kod, dane i surowe odpowiedzi modeli zawiera repozytorium pracy [49], gałąź `paper-complexity`.

- `make all`: testy, pomiary, rysunki i pliki PDF.
- `python scripts/measure.py`: pomiary P1, P2, P3 i P5 oraz agregaty pomiaru P4.
- `python scripts/probe.py ollama MODEL`: sonda na modelu lokalnym.
- `python scripts/probe.py claude MODEL --subset gray --samples 2`: sonda toru Claude.
- `python -m src.pklint --tex PLIK`: sprawdzarka reguł PK dla pliku LaTeX.